

Categorización de retinopatía diabética utilizando algoritmos de inteligencia artificial

Héctor Fabio Ocampo Arbeláez

**Universidad del Valle Sede Tuluá
Facultad de ingeniería
Escuela de ingeniería de sistemas y computación
Tuluá Valle del Cauca
2018**

Categorización de retinopatía diabética utilizando algoritmos de inteligencia artificial

Héctor Fabio Ocampo Arbeláez
Código 1355858
hector.ocampo@correounivalle.edu.co

Director
Carlos Andrés Delgado Saavedra
Profesor de la Escuela de Ingeniería de Sistemas y Computación
carlos.andres.delgado@correounivalle.edu.co

Universidad del Valle Sede Tuluá
Facultad de ingeniería
Escuela de ingeniería de sistemas y computación
Tuluá Valle del Cauca
2018

Tabla de Contenido

1. Preliminares.	1
1.1. Problema	1
1.1.1. Descripción del Problema.	1
1.1.2. Formulación del Problema.	2
1.2. Justificación	2
1.3. Objetivos	3
1.3.1. Objetivo general	3
1.3.2. Objetivos específicos	3
1.4. Resultados esperados	4
1.5. Alcances de la propuesta	5
2. Marco Teórico	5
2.1. Glosario	5
2.2. Inteligencia artificial	6
2.2.1. Búsqueda del estado solución.	7
2.2.2. Algoritmos genéticos.	7
2.2.3. Redes neuronales artificiales	8
2.2.4. Máquinas de soporte vectorial	9
2.3. Aprendizaje de los algoritmos	10
2.3.1. Aprendizaje supervisado	10
2.3.2. Aprendizaje no supervisado	10
2.4. Diabetes Mellitus	11
2.4.1. La diabetes Mellitus Tipo 1	11
2.4.2. La diabetes Mellitus Tipo 2	11
2.4.3. Diabetes Mellitus Gestacional (GDM)	11
2.5. Retinopatía Diabética	11
2.5.1. Retinopatía diabética no proliferativa (RDNP)	12
2.5.2. Retinopatía diabética proliferativa(RDP):	13
2.6. Exámenes para el diagnóstico de retinopatía diabética	15
2.6.1. Angiografía fluoresceínica (AGF)	15
2.6.2. Fondo de ojo	15
2.6.3. Tomografía de coherencia óptica(OCT)	15
2.7. Messidor base de datos	16
3. Marco Referencial:	16
3.1. Marco Referencial de Algoritmos Computacionales:	16
3.2. Marco Referencial de Medicina:	19
4. Base de Datos:	25

5. Implementación	26
5.1. Selección	26
5.2. Red Neuronal Artificial:	27
5.2.1. Función de predicción:	28
5.2.2. Complejidad Función de Predicción:	29
5.3. Backpropagation:	29
5.3.1. Complejidad algoritmos de Backpropagation:	30
5.4. Algoritmos Genéticos:	31
5.4.1. Cromosoma:	31
5.4.2. Población Inicial:	33
5.4.3. Selección por ruleta:	33
5.4.4. Reproducción Directa:	34
5.4.5. Mutación Gaussiana:	34
5.4.6. Reemplazo:	34
5.4.7. Función de evaluación:	35
5.4.8. Función de Aptitud o Fitness:	35
5.4.9. Escalado:	35
5.4.10. Diagrama de flujo	35
5.4.11. Complejidad Algoritmos Genéticos.	36
5.5. SVM	37
5.5.1. Complejidad SVM	41
6. Pruebas:	42
6.1. Backpropagation:	42
6.2. Algoritmos Genéticos:	44
6.3. SVM	50
7. Prototipo	51
8. Comparación:	52
9. Conclusiones:	55
9.1. Trabajos Futuros:	57
10.Referencias	57

Índice de Figuras

1.	Proceso de un algoritmo genético.	7
2.	Diferentes arquitecturas de redes neuronales.	9
3.	Hiperplanos de separación.	10
4.	Anatomía del ojo.	12
5.	Foto de la retina con retinopatía diabética no proliferativa.	13
6.	Foto de la retina con retinopatía diabética proliferativa.	14
7.	Diagrama de dispersión de los datos.	26
8.	Arquitectura de la Red Neuronal.	30
9.	Arquitecturad de la red Neuronal de ejemplo.	32
10.	Diagrama de flujo del algoritmo.	36
11.	Matriz de correlación	38
12.	Diagrama de comparación de los datos X7 y X16, Correlación Nula	39
13.	Diagrama de comparación de los datos X7 y X8, Correlación Negativa . . .	40
14.	Diagrama de comparación de los datos X6 y X7, Correlación Positiva . . .	40
15.	Comportamiento Backpropagation.	43
16.	Comportamiento algoritmo evolutivo, Prueba número 2.	45
17.	Comportamiento algoritmo evolutivo, con un escalado de 1,1.	46
18.	Comportamiento algoritmo evolutivo, con un escalado de 0,9.	46
19.	Comportamiento algoritmo evolutivo, con un escalado de 1,0000001.	47
20.	Comportamiento algoritmo evolutivo, con un escalado de 0,999999.	48
21.	Comportamiento algoritmo evolutivo, con una población de 100	49
22.	Comportamiento de las 4 Pruebas.	50
23.	Captura de la pantalla Principal de la interfaz	52
24.	Curva ROC Comparando las diferentes técnicas	53

Índice de Tablas

1.	Resultados esperados por objetivo específico	4
2.	Clasificación de la retinopatía diabética	15
3.	Marco Referencial Algoritmos Computacionales.	18
4.	Marco Referencial de Medicina	24
5.	Parámetros de la Base de datos	25
6.	Precisión Pruebas Backpropagation	43
7.	Variables del algoritmo genético	44
8.	Combinaciones de las pruebas de algoritmos evolutivos	45
9.	Pruebas Finales	49
10.	Resultados Pruebas SVM	50
11.	Comparación.	55

Agradecimientos

Al profesor Carlos andrés delgado, por aceptar la dirección de mi trabajo de grado, por estar dispuesto a responder cualquier inquietud que tuviera, además a los buenos consejos para tener un buen desarrollo del proyecto, por último y no menos importante a su dedicación y gran labor como docente.

A la universidad del valle, por brindarme la oportunidad de estudiar aquí, de formarme como un profesional ingeniero de sistemas, y hacerme entender que para conseguir las metas hay que esforzarse.

A todos los profesores que hicieron parte de mi formación ética y profesional, de ellos obtuve un conocimiento integral y completo, el cual fue aplicado en el desarrollo de este proyecto y servirá para todo mi futuro.

Dedicatoria

Dedico a mi madre, ella me enseñó a diferenciar lo bueno de lo malo y su labor fue magistral, ella siempre ha estado conmigo apoyándome en todo lo que quiero hacer, y siempre podré contar con ella.

A mi hermana, ya que me siento orgulloso de ser un profesional y quiero ser un ejemplo a seguir para ella, para que siga estudiando con muchos ánimos y pueda lograr todas sus metas.

A toda mi familia, especialmente a mis tíos y abuela, ya que de ellos siempre tuve un apoyo emocional y económico cuando lo necesité.

A Lorena Sánchez Fernández, ella siempre me incentivó a hacer lo que quería, me brindó su ayuda para lo que necesitara y me acompañó en todo el proceso.

Por último a mis compañeros y amigos, con los cuales tuve tiempo para compartir, para estudiar, reforzar todo lo aprendido en la carrera e hicieron de este proceso mucho más agradable.

Introducción

La medicina es una disciplina que se basa y se apoya en el uso de tecnologías, en un caso más concreto software. Existe un término que define esta relación, la Informática Médica, la cual combina diferentes características de la medicina (historias clínicas y lenguajes médicos formales) con tecnología (sistemas de información, inteligencia artificial y cibernética) [1]. A partir de la informática médica se han creado herramientas inteligentes para el apoyo de las decisiones y diagnósticos de los médicos [2]. Estas herramientas pueden utilizar técnicas de inteligencia artificial para aprender de historias clínicas y así poder relacionar diferentes síntomas con el diagnóstico final.

El diagnóstico oportuno de una enfermedad es importante, ya que en caso de que sea una enfermedad con un alto riesgo para el paciente, esta debe ser tratada a tiempo, como por ejemplo lo es la diabetes mellitus (de ahora en adelante diabetes), esta es una enfermedad muy prevalente en el mundo. Hoy en día en Colombia la diabetes está entre las 10 principales causas de mortalidad, así mismo el Ministerio de Salud (MINSALUD) reporta que en el 2012 su prevalencia en la población entre los 18 y 69 años es de 2 millones de personas y con proyecciones de alza en los próximos años [3].

Por otro lado la diabetes afecta diferentes sistemas del cuerpo, generando otras enfermedades como lo son: insuficiencia renal, amputaciones no traumáticas, y pérdida de la visión por culpa de la retinopatía diabética [4], la cual será el centro de atención en este proyecto.

El software desarrollado en el proyecto pretende apoyar al médico en su diagnóstico de retinopatía diabética, así recopilar información para el futuro y trabajar en pro de los pacientes y/o necesitados.

1. Preliminares.

1.1. Problema

1.1.1. Descripción del Problema.

La Diabetes Mellitus es una enfermedad crónica incurable, según la Organización Mundial de la Salud (OMS) para el 2014 habían 422 millones de personas con diabetes en el mundo [5], convirtiéndola en una de las enfermedades más comunes y prevalentes en la actualidad. La diabetes puede provocar ceguera, ataques cardíacos, accidentes cerebrovasculares, insuficiencia renal, amputación de piernas, y daños neurológicos, por ende el paciente debe seguir un control y tratamiento específico [4].

La ceguera causada por la diabetes proviene de la detención o disminución de la sangre por las arterias de la retina del ojo (isquemia retinal), el ojo trata de compensar el problema creando vasos sanguíneos que sangran fácilmente y crecen sin control trayendo como consecuencia la pérdida de visión [4]. A esta enfermedad se le llama retinopatía diabética y se le atribuye un 2.6 % de los casos de ceguera en el mundo [5].

Por lo general, un paciente diabético asiste a un médico general para llevar un control y tratamiento de su enfermedad. Allí periódicamente o cuando el paciente lo requiere se le realiza una revisión de fondo de ojo y se determina si es remitido o no a un oftalmólogo, éste realizará una Angiografía Fluoresceínica [6] en el cual se toma una foto de la retina del ojo, para visualizar diferentes características del mismo que serán esenciales para el diagnóstico de retinopatía diabética. Un problema que existe es que así el médico tenga el conocimiento necesario, no siempre tiene la experiencia suficiente con la enfermedad, por lo que su dictamen médico en algunos casos no será el correcto; además existen variables que pueden afectar directa o indirectamente en el diagnóstico, como lo puede ser el tiempo, los implementos con lo que se trabaja, o el exceso de confianza de los médicos en su dictamen [7].

Ya que la medicina trabaja en pro de la salud de las personas se debe minimizar el número de casos de diagnósticos falsos negativos (diagnóstico negativo / enfermedad presente), ya que puede terminar en una ceguera parcial o total. En caso contrario los falsos positivos (diagnóstico positivo/ enfermedad ausente) el paciente no se verá afectado y con exámenes posteriores se determinará un diagnóstico correcto.

Hoy en día muchas entidades tecnológicas y de la salud han promovido el desarrollo de sistemas expertos como MYCIN [8], TMYCIN [9] y TROPICAID [10] que sirven para apoyar y facilitar al médico su labor en la toma de decisiones. Una característica de los sistemas expertos antes mencionados es que trabajan sobre una enfermedad o conjunto de enfermedades específicas y esto se debe a que no se puede crear un sistema experto que trabaje en cualquier diagnóstico debido a que:

1. Existe una gran cantidad de síntomas y enfermedades. Por esto se debe ir desglosando el problema, trabajando de forma más específica para facilitar el análisis, la

implementación y las pruebas.

2. Existen diferentes técnicas computacionales que pueden variar en su resultado bajo una misma entrada, por lo que se debe hacer un análisis para determinar cuál será la mejor técnica a aplicar en el caso específico.

Dadas estas dos razones hoy en día se llevan a cabo muchas investigaciones y desarrollos en esta área, como lo son las simulaciones del esparcimiento de una enfermedad [11], procesamiento de radiografías [12], análisis de datos clínicos [13] y diagnóstico de enfermedades tales como cáncer o diabetes.

Los algoritmos de inteligencia artificial pueden ser buenos en el diagnóstico de enfermedades, ya que estos son tolerantes al ruido, y se pueden adaptar a los síntomas que son variables con el tiempo [14]. A partir de todo lo expresado anteriormente, se propone realizar un análisis de algoritmos de inteligencia artificial para el diagnóstico de retinopatía diabética y generar un aporte al estudio y diseño de sistemas expertos que servirán de apoyo a los médicos para confirmar su diagnóstico.

1.1.2. Formulación del Problema.

¿Cómo clasificar retinopatía diabética utilizando algoritmos de inteligencia artificial?

1.2. Justificación

La retinopatía diabética es una de las principales causas de ceguera en el mundo y el tratamiento más eficaz es la prevención [4], por esta razón un diagnóstico certero es indispensable, y así posteriormente disminuir la probabilidad de sufrir pérdida de visión parcial o total.

La intención de utilizar algoritmos de inteligencia artificial se basa en que ésta tiene muchas áreas de aplicación, además que promete trasladarse de entornos estáticos y accesible a entornos dinámicos e inaccesibles los cuales se asemejan más al mundo real [14].

En el caso concreto de la medicina, los sistemas que implementan inteligencia artificial para el apoyo en la toma de decisiones de los médicos son usados ya que el dominio de los diagnósticos existen numerosas variables que afectan el proceso de decisión [2], diferentes factores de riesgo, como el tiempo, el exceso de confianza del médico sobre el dictamen que da [7], los síntomas en los pacientes pueden ser variables y en algunos casos incompletos o difusos, es aquí donde la inteligencia artificial hace uso de sus ventajas de adaptarse a cambios, ser tolerantes al ruido de los datos y servir de apoyo a los médicos para mejorar la precisión en su dictamen, dándole una visualización de los síntomas y brindarle más opciones al médico para no tener visión de túnel al momento de tomar la decisión [15].

Además, el avance de la inteligencia artificial en la ciencia computacional es importante y se puede evidenciar en la gran cantidad de investigaciones y proyectos que se llevan

a cabo dado el amplio dominio de aplicación que tiene. En el proyecto actual se analiza el comportamiento de SVM y de redes neuronales artificiales entrenadas por dos técnicas diferentes, backpropagation y algoritmos genéticos; explorando varias configuraciones y opciones, para después compararlas bajo las mismas condiciones y así dejar junto a los estudios ya realizados las bases para los futuros proyectos que tendrán como enfoque el diagnóstico de enfermedades.

Así, con el proyecto actual se cumplirá con un objetivo importante en las investigaciones y desarrollos en el área de la medicina, el cual es mejorar en pro la salud de la población, ya que a partir de los diferentes estudios e investigaciones se busca aportar una experiencia para que en un futuro sirva a la generación de mejores sistemas, los cuales serán de uso directo de los médicos pero al final los principales beneficiados serán los pacientes, ya que posiblemente disminuirán los casos de falsos negativos y posteriormente disminuir los casos de alto riesgo en la salud del paciente.

1.3. Objetivos

1.3.1. Objetivo general

Realizar una categorización positiva o negativa de retinopatía diabética utilizando algoritmos de inteligencia artificial a partir de características obtenidas de imágenes de la retina.

1.3.2. Objetivos específicos

1. Analizar diferentes fuentes de datos relacionados con retinopatía diabética para determinar las variables que se requieren para el diagnóstico.
2. Diseñar e implementar dos estrategias para la categorización de la retinopatía diabética utilizando algoritmos de inteligencia artificial.
3. Desarrollar una aplicación prototipo que permita generar una categorización de retinopatía diabética, teniendo en cuenta las variables asociadas a la enfermedad.
4. Realizar pruebas de los algoritmos y crear un análisis comparativo de los resultados obtenidos en éstos.

1.4. Resultados esperados

Objetivo específico	Resultados esperados	Evidencia del Objetivo
Analizar diferentes fuentes de datos relacionados con retinopatía diabética para determinar las variables que se requieren para el diagnóstico.	<ul style="list-style-type: none">■ Documento donde se expliquen las variables e información relevante para el diagnóstico y el desarrollo del proyecto.■ Conjunto de bibliografía importante para el desarrollo del proyecto.	<ul style="list-style-type: none">■ Cap: 2■ Cap: 3.1■ Cap: 4■ Cap: 5
Diseñar e implementar estrategias para la categorización de la retinopatía diabética utilizando algoritmos de inteligencia artificial..	<ul style="list-style-type: none">■ Documento donde se especifique el análisis y diseño de cada uno de los algoritmos.■ Código fuente de cada una de las técnicas de inteligencia artificial implementadas.	<ul style="list-style-type: none">■ Cap: 5
Desarrollar una aplicación prototipo que permita generar una categorización de retinopatía diabética, teniendo en cuenta las variables asociadas a la enfermedad.	<ul style="list-style-type: none">■ Software prototipo con interfaz gráfica el cual permite ingresar los datos para generar el diagnóstico utilizando los algoritmos previamente implementados.	<ul style="list-style-type: none">■ Cap: 5■ Cap: 7
Realizar pruebas de los algoritmos y crear un análisis comparativo de los resultados obtenidos en éstos.	<ul style="list-style-type: none">■ Documento con el análisis comparativo, anexando gráficas, tablas, indicadores de desempeño, conclusiones y análisis sobre los resultados de cada algoritmo.	<ul style="list-style-type: none">■ Cap: 6■ Cap: 8

Tabla 1: Resultados esperados por objetivo específico

1.5. Alcances de la propuesta

Una vez concluido el proyecto se espera tener un prototipo de un sistema para el diagnóstico de retinopatía diabética, el cual tendrá como entrada características previamente obtenidas de una imagen de la retina del ojo.

El prototipo del sistema no será una herramienta para el usuario final, pero contará con la funcionalidad básica de permitir ingresar los datos y seleccionar con cuál de los dos algoritmos de inteligencia artificial generar el diagnóstico. Se debe aclarar que cuando se habla de generar un diagnóstico, este resultado tiene como objetivo servir de ayuda al médico en la toma de su decisión y no reemplazarlo en ningún caso.

En este proyecto se usarán dos algoritmos de inteligencia artificial principalmente por el tiempo correspondiente para el desarrollo (8 meses), además al ser dos permitirá tener dos resultados posiblemente diferentes, para ser almacenados en tablas y representados en gráficas para tener un punto de comparación directa del desempeño de cada uno.

Existen diferentes proyectos que proponen otros algoritmos para categorizar la retinopatía diabética, lo cual permitirá tener una base para el desarrollo y resultados sobre los cuales comparar los obtenidos en el proyecto, poder generar conclusiones sobre éstos y determinar cuál podría ser el mejor algoritmo a implementar en posteriores sistemas de apoyo para la toma de decisiones del médico.

2. Marco Teórico

2.1. Glosario

- **AGF** : Angiografía fluoresceínica.
- **C** : Clasificación de retinopatía diabética.
- **DM** : Diabetes mellitus.
- **DM tipo 1**: Diabetes mellitus tipo 1.
- **DM tipo 2**: Diabetes mellitus tipo 2.
- **ECM**: Error Cuadrático Medio.
- **EM** : Edema Macular.
- **ES** : Estrategias evolutivas.
- **Exudados (EX)**: Inflamaciones que se depositan en los tejidos o cavidades del organismo.
- **EYT** : Exámenes y tratamientos.

- **GDM** : Diabetes mellitus gestacional.
- **GEP** : Programación de expresión genética.
- **Hemorragia** : Salida de sangre de las arterias, venas o capilares por donde circula.
- **IA** : Inteligencia Artificial.
- **Isquemia** : Detención o disminución de la circulación de sangre a través de las arterias de una determinada zona.
- **LCS** : Learning Classifier Systems - Sistemas Clasificadores.
- **Mácula** : Área muy pequeña en el centro de la retina.
- **Microaneurisma (MA)**: Aneurismas muy pequeños.
- **OCT** : Tomografía de coherencia optica.
- **Retina** : Tejido que cubre la parte posterior del ojo.
- **Retina periférica**: Es la parte alrededor de la retina.
- **Retinopatía diabética** : Enfermedad ocular producida por la diabetes.
- **RDNP** : Retinopatía diabética no proliferativa.
- **RDP** : Retinopatía diabética proliferativa.
- **Vítreo** : La sustancia gelatinosa en el centro del ojo.

2.2. Inteligencia artificial

La inteligencia artificial se puede definir en 4 categorías diferentes [16]:

1. Sistemas que piensan como humanos: “Actividades que vinculamos con procesos de pensamiento humano, actividades como la toma de decisiones, resolución de problemas, aprendizaje”.(Bellman, 1978).
2. Sistemas que piensan racionalmente: “El estudio de las facultades mentales mediante el uso de modelos computacionales”.(Charniak y McDermott, 1985).
3. Sistemas que actúan como humanos: “El arte de desarrollar máquinas con capacidades para realizar funciones que cuando son realizadas por personas requieren de inteligencia”.(Kurzweil, 1990).
4. Sistemas que actúan racionalmente: “La inteligencia computacional es el estudio del diseño de agentes inteligentes”.(Poole, 1998).

La inteligencia artificial es un área multidisciplinaria que estudia la creación y diseño de sistemas capaces de resolver problemas por sí misma utilizando modelos principalmente inspirados en la biología, algunas ramas de la inteligencia artificial son:

2.2.1. Búsqueda del estado solución.

Esta técnica busca la solución de un problema a partir de los posibles estados que puede tener, a diferencia de las soluciones ingenuas que consiste en recorrer todos estados posibles. La inteligencia artificial usa principalmente árboles de búsqueda, que toma como raíz un estado inicial y a partir de diferentes técnicas, éste se va expandiendo y generando estados posibles, donde la decisión es tomada a partir de una heurística diseñada para el problema en específico [16].

Las heurísticas son funciones que evalúan un estado y le asignan un valor a ésta, las heurísticas son importantes ya que de ésta depende que el algoritmo de inteligencia artificial cumpla su objetivo, por lo tanto un buen diseño de una función heurística es indispensable, sin dejar de lado la complejidad temporal y espacial, dado que en algunos casos la respuesta debe ser lo más rápido posible.

2.2.2. Algoritmos genéticos.

Son algoritmos de búsqueda de óptimo basados en la teoría de la evolución de Darwin. Consiste en definir un cromosoma para así crear una población que al ser sometidos a reproducción, acciones aleatorias como la mutación y un criterio de selección, los más aptos sobrevivirán y éstos serán las mejores soluciones del problema [17]. Una descripción gráfica del proceso se ilustra en la figura 1.

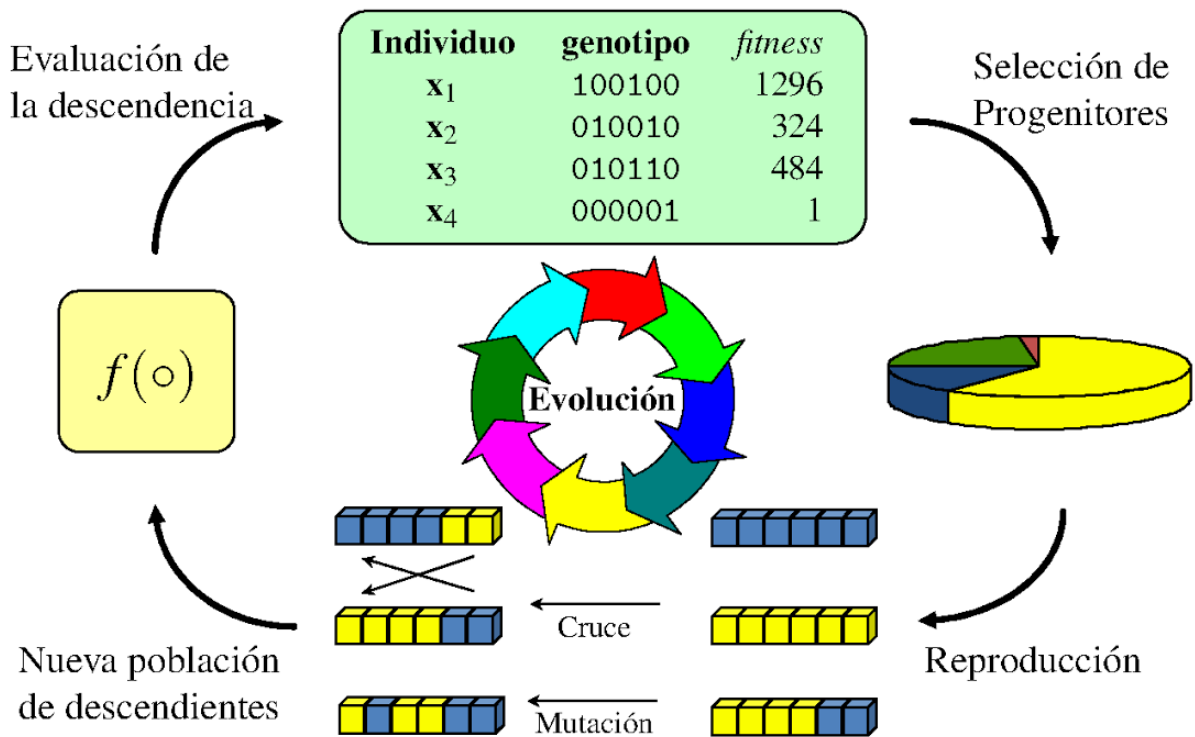


Figura 1: Proceso de un algoritmo genético.

Existen diferentes técnicas aplicadas a los algoritmos evolutivos lo cual hace que se adapte a diferentes problemas:

- **Programación de expresión genética (GEP):** utiliza poblaciones de programas informáticos los cuales son codificados en cromosomas lineales de longitud fija que posteriormente son representados en árboles de expresión [17].
- **Estrategias evolutivas (ES):** consiste en evolucionar a los individuos por medio de la mutación y la recombinación, utiliza la autoadaptación para ajustar los parámetros de control de búsqueda [17].
- **Sistemas Clasificadores:** también llamados Learning Classifier Systems (LCS), consiste en generar reglas de inferencia para que a partir de una entrada dar como salida una clasificación. Esta técnica necesita de datos iniciales sobre los cuales trabajar y a medida que se vaya usando el algoritmo las reglas se irán ajustando [17].
- **Simulated Annealing (SA):** SA es una búsqueda de generar y probar técnicas basadas en una analogía física, más que biológica. Sin embargo, las SA puede ser vista como un proceso evolutivo con población de tamaño 1, representación dependiendo del problema, mutación y un mecanismo específico de supervivencia. la presión selectiva cambia durante el curso del algoritmo.
En este mecanismo el parámetro de la temperatura disminuye según un esquema predefinido dependiente del tiempo, haciendo que la probabilidad de aceptar soluciones inferiores sea cada vez pequeña [17].

2.2.3. Redes neuronales artificiales

Esta técnica está motivada en modelar la forma del procesamiento de la información en sistemas nerviosos biológicos, principalmente por la forma del funcionamiento del cerebro humano. Dado esto una red neuronal artificial es un procesador de información construido por unidades sencillas de procesamiento llamadas neuronas, algunas características son: adquirir conocimiento a partir de la experiencia, adaptabilidad, tolerancia a fallas y comportamiento no lineal [18].

¹Imagen tomada de: <http://www.cs.us.es/~fsancho/?e=65> ultima visita: 09-05-2017

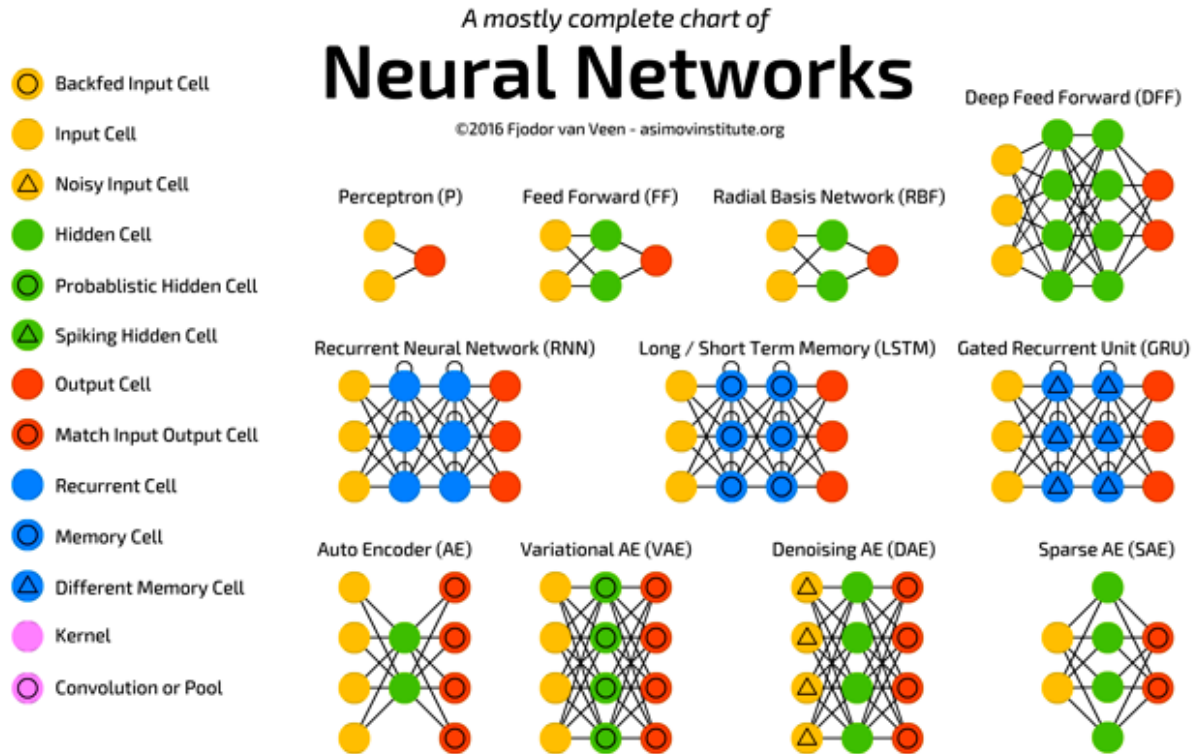


Figura 2: Diferentes arquitecturas de redes neuronales.

2

La figura 2 muestra diferentes arquitecturas de redes neuronales, donde cada una de ellas puede tener un mejor comportamiento sobre un problema en específico, y a medida que avanza los estudios de la inteligencia artificial nuevas arquitecturas de redes neuronales aparecen para ampliar y mejorar esta área.

La construcción de una red neuronal consiste en generar un modelo o seleccionar y adaptar uno ya existente, identificar las entradas, salidas y calcular los pesos de la sinapsis. Este último es importante ya que de estos pesos depende la decisión final que tendrá la red neuronal. Para calcular estos pesos existen varias técnicas que consisten en prueba y error hasta llegar a nivel de satisfactibilidad, a este proceso se le llama aprendizaje de la red neuronal.

2.2.4. Máquinas de soporte vectorial

Son un conjunto de algoritmos centrados principalmente en la clasificación y regresiones lineales, se encuentra entre los algoritmos de aprendizaje supervisado, para la clasificación crea un conjunto de hiperplanos en espacios dimensionales altos [19].

²Imagen tomada de: http://www.example.com/the_image.png ultima visita: 09-05-2017




Figura 3: Hiperplanos de separación.

3

La figura 4 muestra dos gráficas donde (a) solo contiene un hiperplano de separación, (b) muestra más hiperplanos de separación de los datos. Y aunque se puedan crear diferentes hiperplanos de separación se debe de encontrar un hiperplano óptimo el cual esté equidistante de las dos categorías de datos.

2.3. Aprendizaje de los algoritmos

Los algoritmos de inteligencia artificial en sus procesos de decisión deben ser entrenados, para cada algoritmo puede variar la implementación pero en general existen dos tipos de aprendizaje:

2.3.1. Aprendizaje supervisado

Consiste en generar valores capaces de determinar correctamente la respuesta, esto lo debe de hacer a partir de una serie de ejemplos mostrados, los cuales son los datos de entrenamiento, para ello debe de generalizar de los estados presentados a las situaciones no vistas previamente [18].

2.3.2. Aprendizaje no supervisado

Consiste en generar valores a un modelo, donde estos valores serán principalmente generados por el experto a partir de observaciones, y es aquí donde se distingue del aprendizaje supervisado donde no hay un conjunto de conocimiento inicial [18].

³imagen tomada de: [urlhttp://www.ia.uned.es/ejcarmona/publicaciones/\[2013-Carmona\]%20SVM.pdf](http://www.ia.uned.es/ejcarmona/publicaciones/[2013-Carmona]%20SVM.pdf) última visita 09-05-2017.

2.4. Diabetes Mellitus

La diabetes Mellitus (DM) comprende un grupo de trastornos metabólicos frecuentes que comparten el fenotipo de altos niveles de glucosa en sangre (Hiperglucemia). De acuerdo con la causa de la DM, los factores que contribuyen a la hiperglucemia pueden ser deficiencia de la secreción de insulina, disminución de la utilización de glucosa o aumento de la producción de ésta. En Estados Unidos, la DM es la primera causa de enfermedad renal en etapa terminal, de amputaciones no traumáticas de extremidades inferiores (pie diabético) y pérdida potencial de la visión a causa de la retinopatía diabética [4].

Las dos categorías amplias de la DM se designan tipo 1 y tipo 2, éstos dos tipos de diabetes son antecedidos por una fase de metabolismo anormal de glucosa.

2.4.1. La diabetes Mellitus Tipo 1

Anteriormente llamada DM insulino dependiente, en esta forma de diabetes las células Beta son destruidas lo que habitualmente provoca deficiencia completa o casi total de insulina [4].

2.4.2. La diabetes Mellitus Tipo 2

Llamada anteriormente DM no insulino dependiente, presenta diversos trastornos que se caracterizan por grados variables de resistencia a la insulina, menor secreción de dicha hormona y una mayor producción de glucosa [4].

2.4.3. Diabetes Mellitus Gestacional (GDM)

La intolerancia a la glucosa que se desarrolla durante el embarazo se clasifica como diabetes gestacional. Aunque esta forma de diabetes en general desaparece después del parto, una mujer que haya tenido diabetes gestacional tiene mayor probabilidad de presentar diabetes tipo 2 más adelante [4].

2.5. Retinopatía Diabética

Es la enfermedad ocular diabética más común, ocurre cuando los niveles de azúcar en la sangre son muy altos durante largos períodos de tiempo, los capilares (pequeños vasos sanguíneos) que suministran sangre a la retina pueden deteriorarse. Con el tiempo, estos vasos sanguíneos comienzan a filtrar líquidos y grasas, produciendo un edema (hinchazón). Eventualmente, una condición llamada isquemia puede ocurrir, durante la cual los vasos sanguíneos pueden taparse. En otros casos, nuevos vasos sanguíneos anormales crecen en la superficie de la retina [20].

- **La retina:** Es una capa fina de tejido sensible a la luz que cubre la parte posterior del ojo. Los rayos de luz se enfocan en la retina, donde son transmitidos al cerebro e interpretados como imágenes.
- **La retina periférica:** Es la parte alrededor de la retina, es responsable por la visión lateral o periférica.
- **La mácula:** Es un área muy pequeña en el centro de la retina. La mácula es el área responsable por la visión detallada, permitiéndonos leer, coser o reconocer una cara.




Figura 4: Anatomía del ojo.

4

Existen dos tipos de retinopatía diabética:

2.5.1. Retinopatía diabética no proliferativa (RDNP)


La retinopatía diabética no proliferativa (RDNP) es la etapa más temprana de la retinopatía diabética. Cuando existe esta condición, los vasos sanguíneos deteriorados permiten un escape de fluidos de sangre dentro del ojo. Ocasionalmente, depósitos de colesterol u otras grasas de la sangre pueden entrar en la retina [20].

La RDNP puede causar cambios en los ojos, incluyendo:

- **Microaneurismas:** Unas pequeñas protuberancias en los vasos sanguíneos de la retina que con frecuencia dejan escapar líquidos [20].
- **Hemorragias de la retina:** Unas pequeñas manchas de sangre que entran a la retina [20].
- **Exudados duros:** Es la inflamación o engrosamiento de la mácula a causa de escapes de líquido de los vasos sanguíneos de la retina. La mácula no funciona correctamente cuando está inflamada. El edema macular es la causa más común de pérdida de la visión durante la diabetes [20].

⁴Imagen tomada de: <https://www.aaof.org/salud-ocular/enfermedades/retinopatia-diabetica>
ultima visita: 09-05-2017

- **Exudados macular:** Es la inflamación o engrosamiento de la mácula a causa de escapes de líquido de los vasos sanguíneos de la retina. La mácula no funciona correctamente cuando está inflamada. El edema macular es la causa más común de pérdida de la visión durante la diabetes [20].
- **Isquemia macular:** Los pequeños vasos sanguíneos (capilares) se cierran o se tapan. Su visión se torna borrosa ya que la mácula no recibe suficiente sangre para funcionar correctamente [20].



Source: K.J. Knoop, L.B. Stack, A.B. Storrow, R.J. Thurman:
The Atlas of Emergency Medicine, 4th Edition,
www.accessemergencymedicine.com
Copyright © McGraw-Hill Education. All rights reserved.

Figura 5: Foto de la retina con retinopatía diabética no proliferativa.

5

2.5.2. Retinopatía diabética proliferativa(RDP):

La retinopatía diabética proliferativa (RDP) evoluciona a partir de la RDNP y sucede principalmente cuando más grave es la RDNP. La retina en un intento de suministrar sangre a la zona donde los vasos originales se han tapado, la retina responde creando nuevos vasos sanguíneos. Este proceso se llama neovascularización. Sin embargo, los nuevos vasos sanguíneos también son anormales y no proporcionan a la retina con el flujo sanguíneo adecuado. A menudo, los nuevos vasos van acompañados por tejidos cicatrizados que pueden hacer que la retina se arrugue o se desprenda [20].

La RDP puede causar una pérdida de la visión más severa que la RDNP, ya que puede afectar tanto la visión central como la periférica. La RDP afecta la visión de las siguientes maneras:

⁵Imagen tomada de: FUNDUSCOPIC FINDINGS, The Atlas of Emergency Medicine, 4e. ultima visita: 09-05-2017




Figura 6: Foto de la retina con retinopatía diabética proliferativa.

6

- **Hemorragia vítrea:** Los nuevos y delicados vasos sanguíneos sangran dentro del vítreo, previniendo que los rayos de luz lleguen a la retina. Si la hemorragia es pequeña, es posible que la persona afectada vea algunas nuevas manchas oscuras y flotantes. Una hemorragia muy grande puede bloquear la visión, permitiéndole sólo ver la diferencia entre claro y oscuro. Una hemorragia vítrea por sí sola no causa una pérdida de visión permanente. Toda vez que la sangre desaparece, la visión puede volver a su estado anterior, a menos que la mácula se haya dañado [20].
- **Desprendimiento de la retina por tracción:** Cuando el tejido de una cicatriz producida por una neovascularización se encoge, la retina se arruga y puede desprenderse de su posición normal. Estas arrugas maculares pueden distorsionar la visión. Pérdida de la visión más graves pueden ocurrir si la mácula o áreas grandes de la retina se desprende [20].
- **Glaucoma neovascular:** Si una serie de vasos de la retina se cierran, una neovascularización en el iris (la parte coloreada del ojo) puede ocurrir. Cuando esta condición existe, los nuevos vasos sanguíneos pueden bloquear el flujo normal de líquido en el ojo. La presión en el ojo aumenta, lo que presenta una condición particularmente grave que causa daños al nervio óptico [20].

⁶Imagen tomada de: FUNDUSCOPIC FINDINGS, The Atlas of Emergency Medicine, 4e. ultima visita: 09-05-2017

Nivel de severidad	Características
No aparente Retinopatía	No se observan anomalías
Leve NPDR	Se observan el inicio de aparición Microaneurismas
Moderada NPDR	Solo se observan Microaneurismas
Severa NPDR	Se observan Microaneurismas, además se encuentra la presencia de exudados y hemorragias internas
PDR	Presencia de Neovascularización y hemorragia vítrea

Tabla 2: Clasificación de la retinopatía diabética

2.6. Exámenes para el diagnóstico de retinopatía diabética

Existen diferentes tipos de exámenes que apoyan el diagnóstico y manejo de las complicaciones presentadas en la retina de los pacientes diabéticos [6]:

2.6.1. Angiografía fluoresceínica (AGF)

La AGF se basa en el principio de la transmisión de fluorescencia a través de los tejidos de la retina y coroides, captados a través de fotografías con filtros especiales. El colorante de fluoresceína sódica se inyecta en la vena y se registra el comportamiento circulatorio del mismo en la retina. Se toman fotos basales a color con filtros especiales, y luego se toman una serie de fotografías conforme el colorante circula por las venas y arterias de la retina. Las fases tempranas, intermedias y tardías se identifican pasados cerca de diez minutos, tiempo promedio que tarda una angiografía. De acuerdo al comportamiento de los tiempos de llenado y de los patrones observados, el retinólogo obtiene información valiosa acerca del comportamiento circulatorio y de los daños que un paciente pueda tener en la retina [6].

2.6.2. Fondo de ojo

Examen realizado con un oftalmoscopio, es un tipo de microscopio que se utiliza para examinar la parte frontal del ojo, incluyendo párpados, conjuntiva, esclera, cornea, iris, cámara anterior, cristalino, y también partes de la retina y el nervio óptico [6].

2.6.3. Tomografía de coherencia óptica(OCT)

La tomografía de coherencia óptica (OCT por sus siglas en inglés), es una exploración no invasiva con láser que proporciona imágenes de alta resolución de la retina, ayudando a su oftalmólogo a evaluar su espesor. Una tomografía de coherencia óptica puede proporcionar información sobre la presencia y severidad de un edema macular (hinchazón) [6].

2.7. Messidor base de datos

La base de datos Messidor ha sido establecida para facilitar estudios en los diagnósticos asistidos por computador de retinopatía diabética. Los datos en la base de datos son de uso libre para propósitos educativos. Esta base de datos se compone por más de 1000 imágenes de la retina obtenidas de 3 departamentos oftalmológicos diferentes. La explicación de la base de datos propone modelos básicos para el procesamiento de las imágenes, resultados de análisis de las imágenes, y reglas básicas para diagnosticar retinopatía diabética y edemas maculares [21].

3. Marco Referencial:

3.1. Marco Referencial de Algoritmos Computacionales:

Nombre del artículo	Algoritmos Utilizados	Resultados
Detección y clasificación de Retinopatía Diabética no Proliferativa usando una Red Neuronal de Retropropagación [22].	<ul style="list-style-type: none">■ Redes neuronales.	Tuvo una precisión del 95 % en su diagnóstico.
An ensemble-based system for automatic screening of diabetic retinopathy [23].	<ul style="list-style-type: none">■ Redes neuronales.■ SVM.■ Random Forest.■ Árboles de decisión.	Usó diferentes algoritmos de aprendizaje, pero el que mejor resultado dio, fue SVM con una precisión mayor al 95 % (Citado por 35).
Machine Learning on the Diabetic Retinopathy Debrecen Data Set[24]	<ul style="list-style-type: none">■ Redes neuronales.■ SVM.■ Random Forest.■ K-NN.	SVM tuvo la mejor precisión con un 76 %

Nombre del artículo	Algoritmos Utilizados	Resultados
An Improved Medical Decision Support System to Identify the Diabetic Retinopathy Using Fundus Images[25].	<ul style="list-style-type: none"> ▪ SVM. 	Tiene una precisión del 97 %, a diferencias del anterior. Este usa como entrada directamente las imágenes de la retina. (Citado por 6)
An Expert Support System for Breast Cancer Diagnosis using Color Wavelet Features[26].	<ul style="list-style-type: none"> ▪ SVM. ▪ Redes bayesianas. ▪ Redes Neuronales. 	SVM tuvo la mejor precisión con un 98 % (Citado por 16).
Tuberculosis Disease Diagnosis Using Artificial Neural Network Trained with Genetic Algorithm[27].	<ul style="list-style-type: none"> ▪ Redes neuronales entrenadas por algoritmos genéticos. 	Tuvo una precisión del 94 %, mejorando en un 2 % otros estudios anteriores con redes neuronales. (Citado por 44)
Un sistema experto difuso en la Web para diagnóstico de diabetes[28].	<ul style="list-style-type: none"> ▪ Lógica difusa. 	Fue probado por varios médicos, pacientes con y sin diabetes, mostrando que ayuda muchos a los médicos a dar un diagnóstico más certero, teniendo en cuenta más variables y ser más óptimos con el tiempo. (Citado por 1)
Artificial neural networks applied to cancer detection in a breast screening programme[29].	<ul style="list-style-type: none"> ▪ Redes Neuronales. 	Usó 9 modelos de redes neuronales, siendo el primero con 32 neuronas y aumentando hasta el modelo 9 con 484. después del entrenamiento y las pruebas, se encontró que los modelos 5, 6 y 7 tenían los mejores resultados, y siendo el modelo 5 con 144 neuronas la que mejor precisión tuvo, con un 75 %. (citado por 27)

Nombre del artículo	Algoritmos Utilizados	Resultados
A Clinical Decision Support System with an Integrated EMR for Diagnosis of Peripheral Neuropathy[30].	<ul style="list-style-type: none"> ■ Lógica difusa. 	El sistema puede diagnosticar 4 diferentes neuropatías y fue testado con ayuda de expertos, presentando una precisión del 93 %. (Citado por 4)
A Study on Hepatitis Disease Diagnosis Using Probabilistic Neural Network[31].	<ul style="list-style-type: none"> ■ Redes neuronales Probabilísticas(PNN). 	PNN tiene una precisión de 91,2 %, una precisión mayor que muchos otros modelos de redes neuronales para esta enfermedad (Citado por 25).
A Study on Hepatitis Disease Diagnosis Using Multilayer Neural Network with Levenberg Marquardt Training Algorithm[32].	<ul style="list-style-type: none"> ■ Redes neuronales Entrenadas por Levenberg Marquardt(MLNN). 	MLNN tiene una precisión de 91,87 %, siendo así una red neuronal con mayor precisión, esto puede ser a que LM le proporciona una mayor velocidad de convergencia (Citado por 45).
Performance analysis of descriptive statistical features in retinal vessel segmentation via fuzzy logic, ANN, SVM, and classifier fusion[33].	<ul style="list-style-type: none"> ■ Lógica difusa. ■ ANN. ■ SVM. ■ Clasificador de fusión. 	Se usó el sistema en dos bases de datos diferentes, en los dos casos las redes neuronales tuvieron la mejor precisión con un 94 %, seguida por la lógica difusa con un 93 % de precisión (Citado por 4).
Vessel segmentation and microaneurysm detection using discriminative dictionary learning and sparse representation[34].	<ul style="list-style-type: none"> ■ Discriminative dictionary learning. 	Detecta los microaneurismas y vasos de la retina del ojo, es usado en dos bases de datos diferentes, y tiene una precisión del 94 % (Citado por 5).

Tabla 3: Marco Referencial Algoritmos Computacionales.

3.2. Marco Referencial de Medicina:

Nombre	Características								Observaciones	Aporte
	DM	RDNP	RDP	MA	EX	EYT	C	EM		
Comparison of Standardized Clinical Classification with Fundus Photograph Grading for the assessment of Diabetic Retinopathy and Diabetic Macular Edema Severity [35]							x		Propone una clasificación clínica de la retinopatía diabética, mostrando la equivalencia con la tabla de clasificación ETDRS.	Relación de los microaneurismas, exudados y hemorragias para la clasificación clínica de retinopatía diabética, es una clasificación simple.
Diabetic retinopathy - ocular complications of diabetes mellitus [36]		x	x		x	x		x	Habla principalmente de edema macular, y la complicación de la retinopatía diabética.	Importancia del diametro de los exudados para el diagnóstico de edema macular, siendo ésta una complicación de la retinopatía diabética.

Nombre	Características								Observaciones	Aporte
	DM	RDNP	RDP	MA	EX	EYT	C	EM		
ryan' retina volume I [37]		x	x	x	x	x	x	x	Libro muy importante y completo sobre todo lo relacionado con el ojo, es muy técnico y específico en oftalmología.	Relación de los microaneurismas, exudados y hemorragias para la clasificar el nivel de retinoatía diabética.
Preferred Practice Pattern: Diabetic retinopathy [38]		x		x	x	x	x	x	Habla de historia de retinopatía diabética, da la clasificación de la retinopatía y explica un proceso que se debe tener un con un paciente con retinopatía diabética y qué exámenes usar.	Relación de los microaneurismas, exudados y hemorragias para la clasificación de retinopatía diabética. Menciona otras variables como tipo de diabetes, tiempo de pre-diabetes, edad para el diagnóstico de retinopatía diabética.

Nombre	Características								Observaciones	Aporte
	DM	RDNP	RDP	MA	EX	EYT	C	EM		
Diabetic retinopathy [39]		x	x	x	x	x	x		Clasifica la retinopatía diabética, explicando cada estado, y da alguna información más sobre la retinopatía diabética y la relación que esta puede dar para dar un porcentaje de muerte del paciente	Relación de los microaneurismas, exudados y hemorragias para la clasificación de retinopatía diabética e imágenes explicativas.
Retinopatía diabética simplificada [40]		x	x				x	x	Expone y explica: early treatment diabetic retinopathy study(ETDRS). Ya que es una clasificación internacional.	Relación de microaneurismas, exudados, edemas, para la clasificación de retinopatía diabética en la clasificación internacional.
Harrison's Principles of Internal Medicine [4]	x	x		x	x				Libro importante para definición de diabetes y sus cuidados, explica que la retinopatía diabética es una por culpa de la diabetes mellitus.	Explicación de diabetes mellitus, tipos y efectos de ésta.

Nombre	Características								Observaciones	Aporte
	DM	RDNP	RDP	MA	EX	EYT	C	EM		
Teleoftalmología para el cribado de la retinopatía [41]		x	x			x			Explica la Teleoftalmología y como se puede diagnósticas retinopatía diabética a partir de imágenes de la retina tomados por un retinografo.	Examen a distancia para diagnóstico de retinopatía diabética, consiste en tomar fotos de la retina y enviarlas por algún medio electrónico para su revisión, da buenos resultados y es útil para que las imágenes tomadas sean procesadas por sistemas.
United Kingdom Prospective Diabetes Study [42].		x	x	x	x		x		Estudio de datos de pacientes, clasificando estos datos por diferentes variables y ver cómo se comporta la enfermedad en la población.	Menciona otras variables como tipo de diabetes, tiempo de diabetes, edad, para evaluar un riesgo de presencia de retinopatía diabética.

Nombre	Características								Observaciones	Aporte
	DM	RDNP	RDP	MA	EX	EYT	C	EM		
Guía de Retinopatía[6]	x	x	x	x	x	x		x	Guía de retinopatía diabética, donde explica todo muy detalladamente, pero no hace una exploración profunda sobre los temas, pero sirve mucho para dar una definición inicial	Guía donde explica el proceso que debe tener el médico para el diagnóstico, donde también explica que el tiempo de una cita no es suficiente para un bien proceso.
GUIA PRACTICA CLINICA DE RETINOPATIA DIABETICA PARA LATINOAMERICA [43]	x	x	x	x	x	x	x	x	Dirigida a oftalmólogos y profesionales de la salud, explica mucho sobre la retinopatía diabética.	Relacion de microaneurismas para la clasificación de retinopatía diabética, además agrega un porcentaje de progresión de la enfermedad.
Teleoftalmología para el cribado de Retinopatía Diabética en un área de salud integrada: modelo de gestión de la demanda[44]		x	x			x			Análisis de este examen y modalidad para diagnóstico de la enfermedad.	Explicación y proceso del examen para el diagnóstico de retinopatía diabética

Nombre	Características								Observaciones	Aporte
	DM	RDNP	RDP	MA	EX	EYT	C	EM		
Coverage and results of a screening program for diabetic retinopathy using mydriatic retinography in primary health care [45]		x	x			x			Análisis de un proceso para el diagnóstico de retinopatía diabética.	
Chapter 3 . Fundusopic Findings Age-Related Macular Degeneration [46]		x	x	x	x				Capítulo de un libro, donde se explica la retinopatía diabética, tiene ejemplos gráficos para ver los microaneurismas y exudados duros.	Explicación de la retinopatía diabética, microaneurismas, exudados y hemorragias.
Atlas de la Diabetes de la FID [47]	x	x	x						Artículo de la federación internacional de la diabetes, explica mucho sobre toda la diabetes	Sustento teórico de la diabetes mellitus, y prevalencia de ésta en todo el mundo.
PREVALENCIA DE RETINOPATÍA DIABÉTICA EN UNA POBLACIÓN DIABÉTICA [48]		x							Análisis de la prevalencia de retinopatía diabética en una población, muestra que el tiempo de la diabetes es importante para la retinopatía diabética.	El tiempo de la diabetes mellitus en el paciente se puede relacionar con la presencia de retinopatía diabética.

Tabla 4: Marco Referencial de Medicina

4. Base de Datos:

El Dataset usado para el proyecto, son los datos obtenidos del procesamiento de las imágenes de la retina, de la base de datos messidor [21]. éstas imágenes fueron procesadas a partir de los modelos presentados en el artículo “An ensemble-based system for automatic screening of diabetic retinopathy.” [23] obteniendo así 19 parámetros explicados en la tabla 5

Característica	Descripción
X_0	Un resultado que determina la calidad de la imagen (0 = mala; 1= Buena).
X_1	Resultado de un pre-procesamiento, (1 = severa RD o 0 = no Severa RD).
$X_2 \cdots X_7$	Número entero que determina la cantidad de microaneurismas detectados, con un nivel de confianza del 50 % al 100 %, respectivamente.
$X_8 \cdots X_{16}$	Número entero con la cantidad de píxeles que representan un exudado, con un nivel de confianza del 20 % al 100 %, respectivamente.
X_{17}	Valor relativo que determina la distancia del centro de la mácula a el centro del disco óptico.
X_{18}	Resultado de Clasificación AM/FM.

Tabla 5: Parámetros de la Base de datos

Para tener una visión de los datos, la gráfica 7 muestra un diagrama de dispersión de todos los parámetros, donde se puede observar cuáles son los datos que tiene valores máximos y mínimos. Como por ejemplo X_8 el cual representa el número de píxeles de exudados con un nivel de confianza del 20 %, es el parámetro que tiene el valor más alto a comparación de todos los demás. Otra observación que se puede hacer es que el conjunto de parámetros $X_2 \cdots X_7$ el cual representa a los microaneurismas, va disminuyendo de una forma lineal a medida que aumente el porcentaje de confianza, y el conjunto de parámetros $X_8 \cdots X_{16}$ que representan a los exudados, va disminuyendo de forma exponencial a medida que aumente el porcentaje de confianza.




Figura 7: Diagrama de dispersión de los datos.

A partir de esta información se puede normalizar los datos, para que todos los valores estén en el rango $[0,1]$:

- El número de microaneurismas $X_2 \cdots X_7$, es convertido en binarios de 7 dígitos, para que sean 1s y 0s. dado que inicialmente hay 6 parámetros de entrada de microaneurismas, se tendría que se convierten en 42 parámetros de entrada, que sumados con los 13 parámetros restantes daría 55 parámetros de entrada para la red.
- El porcentaje de exudados $X_8 \cdots X_{16}$, es normalizado dividiendo cada uno en el número de píxeles de la imagen original, para que el resultado sea 1s y 0s.

Después de este paso, se obtienen 55 parámetros, y así servirán de entrada de la función de predicción de redes neuronales.

5. Implementación

5.1. Selección

En la computación se tiene una gran cantidad de algoritmos de decisión que se basan en diferentes técnicas de computación, en la Tabla: Marco Referencial de Artículos

de Computación. se puede ver la presencia de algunos algoritmos que se basan principalmente en dos técnicas de computación Redes Neuronales y SVM. Para poder decidir los algoritmos que se van implementar primero toca decidir la técnica computacional en la que cual se va a basar los algoritmos.

La técnica a usar entre las dos mencionadas anteriormente, será seleccionada a partir de lo siguiente:

- Número de citasiones de los artículos en la Tabla 3.1 .
- Número de implementaciones en la Tabla 3.1.
- Mejores Resultados obtenidos en la Tabla 3.1.

Resultados obtenidos:

- Redes neuronales tiene el mayor número de implementaciones en la tabla de antecedentes, con 8 implementaciones a comparación de SVM con 5 veces.
- Redes neuronales tiene el artículo con mayor número de citasiones, «Redes neuronales Entrenadaspor Levenberg Marquardt(MLNN) [32]» con 45 citasiones, el segundo artículo en número de citasiones también implementa redes neuronales, «Tuberculosis Disease Diagnosis Using Artificial Neural Network Trained with Genetic Algorithm[27]» con 44 citasiones, y el tercer artículo en número de citasiones implementa diferentes algoritmos entre ellos redes neuronales y SVM, «An ensemble-based system for automatic screening of diabetic retinopathy [23]», con 35 citasiones.
- Redes neuronales junto con SVM tienen porcentaje de precisión muy alto, teniendo a SVM con su mayor precisión en un 98 % y a redes neuronales con su mejor precisión en un 95 %.

Éstos resultados fueron tomados de artículos publicados en fuentes confiables, siendo así un buen indicador de fiabilidad. y un punto de arranque para el proyecto actual.

5.2. Red Neuronal Artificial:

La implementación de la red neuronal en el actual proyecto se ve dividida en dos:

Función de predicción: En esta función se debe tener en cuenta la arquitectura de la red, para saber como interpretar los pesos sinápticos y que al momento de tener un patrón de entrada, los cálculos de la salida se realicen de la manera correcta, la cual sería la respuesta de la red con respecto al patrón de entrada.

Función de entrenamiento: son los diferentes algoritmos de entrenamientos de la red, que son los encargados de recalcular los pesos de las conexiones sinápticas, para que los resultados de precisión sean cada vez mejores.

5.2.1. Función de predicción:

Una red neuronal puede variar mucho, ya sea en su número de neuronas, en el número de salidas y en su arquitectura, respondiendo a esto en el actual proyecto de usará una sola salida con una arquitectura de perceptrón con una capa oculta y dejando variable el número de neuronas, el cual será un parámetro importante en las pruebas que se deben realizar.

El calculo de la salida de una red neuronal con arquitectura perceptrón, se puede simplificar en multiplicación de matrices, ya que los pesos sinápticos de la red neuronal están almacenados computacionalmente en matrices, en tamaños que responden al tamaño de la red.

Para empezar con la explicación de la implementación de la red neuronal, se deben estandarizar las variables a usar:

- N = número de entradas de la red neuronal = 55
- M = número de neuronas = *Variable*
- S = número de salidas = 1

La función de predicción en casos generales tendrá como entrada la siguientes matrices:

$$PatronEntrada_{(N \times 1)} = \begin{bmatrix} E_1 \\ E_2 \\ \vdots \\ \vdots \\ E_N \end{bmatrix} \quad (1)$$

$$PesosCapaOculta_{(M \times N)} = \begin{bmatrix} W_{11} & W_{12} & W_{13} & W_{14} & W_{15} & \cdots & W_{1N} \\ W_{21} & W_{22} & W_{23} & W_{24} & W_{25} & \cdots & W_{2N} \\ \cdots & & & & & & \\ \cdots & & & & & & \\ \cdots & & & & & & \\ W_{M1} & W_{M2} & W_{M3} & W_{M4} & W_{M5} & \cdots & W_{MN} \end{bmatrix} \quad (2)$$

$$PesosCapaSalida_{(S \times M)} = \begin{bmatrix} P_{11} & P_{12} & P_{13} & P_{14} & P_{15} & \cdots & P_{1M} \\ P_{21} & P_{22} & P_{23} & P_{24} & P_{25} & \cdots & P_{2M} \\ \cdots & & & & & & \\ \cdots & & & & & & \\ \cdots & & & & & & \\ P_{S1} & P_{S2} & P_{S3} & P_{S4} & P_{S5} & \cdots & P_{SM} \end{bmatrix} \quad (3)$$

A partir de estas entradas, primero se debe calcular la salida neta de la capa oculta, esto se realiza por medio de la multiplicación de (2) con (1) y después sumar el bias a los pesos resultantes, teniendo así:

$$SalidaNetaCapaOculta_{(M \times 1)} = PesosCapaOculta_{(M \times N)} * PatronEntrada_{(N \times 1)} \quad (4)$$

Ya habiendo tenido la salida neta de la capa oculta, se haya la salida total de la red, multiplicando 3 con 4, teniendo así:

$$Salida_{(S \times 1)} = PesosCapaSalida_{(S \times M)} * SalidaNetaCapaOculta_{(M \times 1)} \quad (5)$$

Obteniendo un vector con cada una de las salidas de la red. En el actual proyecto se está usando una sola salida, ya que ésta permite dar una clasificación positiva “existencia de la enfermedad = 1” o una clasificación negativa “no hay existencia de la enfermedad = 0”. Por lo tanto la salida total de la red neuronal será un vector de tamaño (1×1) , lo que es lo mismo que un escalar. Una representación de la red neuronal resultante es la que se ve en la gráfica 8.

5.2.2. Complejidad Función de Predicción:

Complejidad temporal: Como ya se mencionó, la implementación de la red neuronal principalmente consiste en multiplicación de matrices, y la complejidad temporal de la multiplicación de matrices depende del tamaño de ellas. en el calculo de la salida se realizan dos multiplicaciones, teniendo como complejidad temporal:

$$SalidaNetaCapaOculta_{(M \times 1)} = PesosCapaOculta_{(M \times N)} * PatronEntrada_{(N \times 1)} \Rightarrow \mathcal{O}(NM)$$

$$Salida_{(1 \times 1)} = PesosCapaSalida_{(1 \times M)} * SalidaNetaCapaOculta_{(M \times 1)} \Rightarrow \mathcal{O}(M)$$

Sumando estas dos complejidades:

$$\mathcal{O}(NM) + \mathcal{O}(M) \Rightarrow \mathcal{O}(NM + M) \Rightarrow \mathcal{O}(NM)$$

Teniendo así, que la complejidad del calculo de una salida de la red neuronal es:

$$\mathcal{O}(NM) \quad (6)$$

Complejidad Espacial: La complejidad espacial del algoritmo consiste el almacenar las matrices, por lo que la complejidad espacial se resume en el tamaño de las matrices:

$$\mathcal{O}(N + NM + M) \Rightarrow \mathcal{O}(NM)$$

5.3. Backpropagation:

Backpropagation o Propagación hacia atrás, es un algoritmo de entrenamiento de Redes Neuronales, este algoritmo utiliza los patrones de salida de la red y la salida obtenida para calcular el error de la salida [18].

Este error se propaga desde la capa de salida, hasta la capa de entrada, hacia atrás. afectando los pesos de cada neurona dado un factor de entrenamiento y su contribución con la salida, así las neuronas que son más determinantes tendrán más cambios a comparación con las neuronas que no son tan significativas.

Para el actual proyecto se implemento el algoritmo backpropagation en una red neuronal de una capa oculta, y se verá de la siguiente forma:




Figura 8: Arquitectura de la Red Neuronal.

5.3.1. Complejidad algoritmos de Backpropagation:

Complejidad temporal: El algoritmo de backpropagation ya que es un algoritmo de entrenamiento de la red neuronal está constantemente recalculando los pesos de las capas, lo que determina una constante iteración en los patrones de entrenamiento, estar usando continuamente la función de predicción y comparar las salidas obtenidas con las deseadas.

- Inicialmente en el algoritmo se obtiene un resultado de un patrón concreto del conjunto de entrenamiento, lo cual tiene una complejidad $\mathcal{O}(NM)$, como se dice en la sección anterior.
- Después, se halla el error de la salida, con respecto a la salida deseada en los patrones de entrenamiento, lo cual tiene una complejidad constante $\mathcal{O}(1)$.
- Ahora se empieza la propagación hacia atrás, primero se recalculan los pesos de la capa de salida, recorriendo el vector de los pesos de la capa de salida y como éste tiene un tamaño de $(M \times 1)$, implica que tiene una complejidad de $\mathcal{O}(M)$.
- Continuando con la propagación hacia atrás ahora se recalculan los pesos de la capa oculta, recorriendo la matriz de pesos de la capa oculta y como ésta tiene un tamaño de $(M \times N)$, implica que tiene una complejidad de $\mathcal{O}(MN)$.

Hasta el momento tenemos diferentes pasos que van en secuencia, por lo que significan que se suman, dejando así:

$$\begin{aligned}
&= \mathcal{O}(NM) + \mathcal{O}(1) + \mathcal{O}(M) + \mathcal{O}(NM) \\
&= \mathcal{O}(NM + 1 + M + NM) \\
&= \mathcal{O}(2NM + M + 1) \\
&= \mathcal{O}(2NM) \\
&= \mathcal{O}(NM)
\end{aligned}$$

En cada iteración del algoritmos se está constantemente ejecutando todos los pasos anteriores por cada patrón de entrenamiento, lo que significa una multiplicación en la complejidad.

T = cantidad de patrones de entrenamiento.

$$\mathcal{O}(TNM)$$

Para finalizar toda la iteración del algoritmo de backpropagation, se tiene en cuenta algo que se llama “punto de aburrimiento”, la cual consiste en colocar un límite concreto de iteraciones o un límite de tiempo de ejecución, teniendo así la complejidad final del algoritmo de entrenamiento:

I = Punto de aburrimiento / cantidad de iteraciones.

$$\mathcal{O}(ITNM) \tag{7}$$

Complejidad Espacial: La complejidad espacial del algoritmo consiste el almacenar las matrices, lo cual sería equivalente a la complejidad espacial de la función de predicción:

$$\mathcal{O}(N + NM + M) \Rightarrow \mathcal{O}(NM)$$

5.4. Algoritmos Genéticos:

Los algoritmos genéticos son una técnica computacional bioinspirada de la evolución de Darwin. Ésta es una técnica exploratoria muy útil en problemas de optimización [17], como lo es el problema de optimizar los pesos de la red neuronal.

La implementación del algoritmo genético puede variar dado diferentes factores, como lo son población inicial, forma de reproducción, porcentaje de mutación, fórmula de mutación, selección, entre otras. todas estas variables pueden generar una gran catidad de posibilidades

5.4.1. Cromosoma:

Para la implementación del algoritmo evolutivo es importante determinar el genotipo y fenotipo del cromosoma, y cómo se representará computacionalmente para su ejecución.

El **Fenotipo:** será la repreceñación de las matrices de pesos y bias usados en la Red neuronal de la Figura 3

$$PesosCapaOculta_{(M*N)} = \begin{bmatrix} W_{11} & W_{12} & W_{13} & W_{14} & W_{15} & \dots & W_{1N} \\ W_{21} & W_{22} & W_{23} & W_{24} & W_{25} & \dots & W_{2N} \\ \vdots & & & & & & \\ \vdots & & & & & & \\ W_{M1} & W_{M2} & W_{M3} & W_{M4} & W_{M5} & \dots & W_{MN} \end{bmatrix}$$

$$PesosCapaSalida_{(1*M)} = [P_{11} \ P_{12} \ P_{13} \ P_{14} \ P_{15} \ \dots \ P_{1M}]$$

$$BiasCapaOculta = B1$$

$$BiasCapaSalida = B2$$

El **Genotipo**: consistirá en un arreglo de tamaño:

$$tamano = M * N + M + 2 \quad (8)$$

con la siguiente indexación:

- Las primetas $M * N$ posiciones representarán la matriz de pesos de la capa oculta.
- Las siguientes M posiciones serán los pesos de la capa de salida.
- La penúltima posición será el bias de la capa oculta.
- La última posición será el bias de la capa de salida.

$$Cromosoma = [W_{11} \ \dots \ W_{1N} \ \dots \ W_{MN} \ P_{10} \ \dots \ P_{1M} \ B1 \ B2]$$

Ejemplo:




Figura 9: Arquitecturad de la red Neuronal de ejemplo.

Esta Red Neuronal de la figura 4 tiene dos entradas $N = 2$, dos Neuronas en la capa oculta $M = 2$ y una salida. que servirá de ejemplo para explicar el algoritmo genético.

El Fenotipo:

$$PesosCapaOcult_{(2*2)} = \begin{bmatrix} W_{11} & W_{12} \\ W_{21} & W_{22} \end{bmatrix}$$

$$PesosCapaSalida_{(1*2)} = \begin{bmatrix} P_{11} & P_{12} \end{bmatrix}$$

$$BiasCapaOcult = B1$$

$$BiasCapaSalida = B2$$

El Genotipo: El tamaño del cromosoma será por lo tanto

$$Tamano = M * N + M + 2 = 2 * 2 + 2 + 2 = 8$$

$$Cromosoma = [W_{11} \ W_{12} \ W_{21} \ W_{22} \ P_{11} \ P_{12} \ B1 \ B2]$$

5.4.2. Población Inicial:

La población inicial en el algoritmo genético será totalmente aleatorio, aunque cumpliendo unas pequeñas reglas. En las pruebas hechas por la implementación de propagación hacia atrás se encontró que los pesos de la capa oculta varían en un rango de $[-1, 1]$, y los pesos de la capa de salida varían en un rango de $[-7, 7]$, dado ésto la generación aleatoria cumplirá estos rangos en los pesos correspondientes. pero igualmente estos rangos no son camisa de fuerza para el algoritmos, ya que por medio de la reproducción y mutación se podrán salir de éstos si es necesario.

Siguiendo con el ejemplo, dos individuos de la población inicial, quedarían así:

$$Cromosoma1 = [-0,98 \ 0,97 \ -0,37 \ 0,11 \ -3,9 \ 4,7 \ 0,9 \ 0,66]$$

$$Cromosoma2 = [-0,42 \ 0,83 \ -0,19 \ 0,03 \ -6,6 \ -5,7 \ 0,4 \ 0,1]$$

5.4.3. Selección por ruleta:

Consiste en asignarle a cada individuo un porcentaje de selección dependiendo de su fitness, siendo que para mejor fitness mayor será el porcentaje de selección y para menor fitness menor porcentaje de selección. organizando estos porcentajes en un arreglo, acumulando los porcentajes posición por posición, en donde la posición final el porcentaje debe ser 100 %, para que cuando la ruleta se ejecute (número random) recorrer el arreglo y encontrar el individuo seleccionado.

$$Ruleta = [0,01 \ 0,03 \ 0,19 \ 0,26 \ 0,30 \ \ 0,94 \ 1]$$

La posición de cada valor, representa a un individuo de la población, por lo tanto en donde caiga la ruleta, será el individuo seleccionado.

5.4.4. Reproducción Directa:

consiste en darle un 50 % de probabilidad de intercambiar de gen al momento de la reproducción.

La reproducción de los cromosomas anteriores serían:

$$Cromosoma1 = [-0.98 \quad 0.97 \quad -0.37 \quad 0.11 \quad -3.9 \quad 4.7 \quad 0.9 \quad 0.66]$$

$$Cromosoma2 = [-0.42 \quad 0.83 \quad -0.19 \quad 0.03 \quad -6.6 \quad -5.7 \quad 0.4 \quad 0.1]$$

$$Hijo1 = [-0.98 \quad 0.83 \quad -0.37 \quad 0.11 \quad -6.6 \quad 4.7 \quad 0.9 \quad 0.1]$$

$$Hijo2 = [-0.42 \quad 0.97 \quad -0.19 \quad 0.03 \quad -3.9 \quad -5.7 \quad 0.4 \quad 0.66]$$

5.4.5. Mutación Gaussiana:

Consiste en sumar un número que corresponde a un número aleatorio de una distribución normal con media en cero y desviación estandar 1.

Las probabilidades de mutación usadas en el proyecto son 8 % y 20 %, utilizando valores altos de mutación para tener una variabilidad alta.

$$Hijo2 = [-0.42 \quad 0.97 \quad -0.19 \quad 0.03 \quad -3.9 \quad -5.7 \quad 0.4 \quad 0.66]$$

$$Hijo2 = [-0.42 \quad 0.56 \quad -0.19 \quad 0.03 \quad -3.9 \quad -5.7 \quad 0.4 \quad 1.25]$$

5.4.6. Reemplazo:

El reemplazo se realiza conservando un porcentaje de la población con mejor fitness, el porcentaje de la población que es reemplazada se puede determinar al inicio de la ejecución.

Ejemplo:

- Para un población de 50 si se coloca un reemplazo de 88 %, la población reemplazada será 44 individuos.
- para una población de 50 si se coloca un reemplazo de 50 % la población reemplazada será 25 individuos.
- Para un población de 100 si se coloca un reemplazo de 94 %, la población reemplazada será 94 individuos.
- para una población de 100 si se coloca un reemplazo de 50 % la población reemplazada será 50 individuos.

5.4.7. Función de evaluación:

Para la evaluación del cromosoma se va a utilizar el error cuadrático medio (ECM), donde un ECM alto significa que el cromosoma está dando respuestas muy alejadas a las esperadas y a menor ECM significa que el cromosoma está dando respuestas más certeras. La evaluación del cromosoma consiste en generar el fenotipo del cromosoma y éste cargarlo en la red neuronal, para que todos los datos del dataset sean evaluados y generar el error cuadrático medio.

$$ECM = \frac{1}{n} \sum_{i=1}^n (\hat{Y}_i - Y_i)^2 \quad (9)$$

5.4.8. Función de Aptitud o Fitness:

La función de aptitud debe ser una función que caracteriza a un cromosoma, entre mejor puntuación mejor será el cromosoma y a menor puntuación peor será el cromosoma, lo contrario del ECM; por lo tanto la función de aptitud será:

$$Aptitud = \frac{1}{ECM} \quad (10)$$

5.4.9. Escalado:

Con intención de aumentar la variabilidad, y no guardar los mismos individuos generación tras generación. se considera implementar un escalado a todo el cromosoma a los individuos que no son reemplazados, para que en la próxima generación tengan un valor diferente pero no muy lejano.

Por ejemplo: si se usa un escalado del 1.1 tendríamos.

$$Cromosoma1 = [-0,98 \quad 0,97 \quad -0,37 \quad 0,11 \quad -3,9 \quad 4,7 \quad 0,9 \quad 0,66]$$

Después del escalado:

$$Cromosoma1 = [-1,078 \quad 1,067 \quad -0,407 \quad 0,121 \quad -4,29 \quad 5,17 \quad 0,99 \quad 0,726]$$

Si se usa un escalado de 1, quiere decir que se deja igual generación tras generación.

5.4.10. Diagrama de flujo

El Diagrama de flujo del algoritmo sería el siguiente:

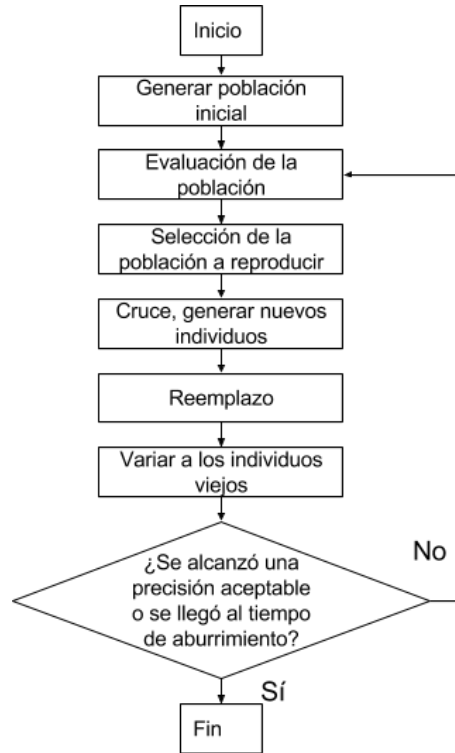


Figura 10: Diagrama de flujo del algoritmo.

5.4.11. Complejidad Algoritmos Genéticos.

Complejidad Temporal: La complejidad temporal de los algoritmos genéticos, depende principalmente de dos variables:

- P = Población.
- G = Tamaño del cromosoma.
- T = cantidad de patrones de entrenamiento.

Como se puede ver en el diagrama de flujo del algoritmo genético, éste consiste en una serie de pasos y cada uno se le encontrará la complejidad temporal.

- Evaluar la población consiste en recorrer cada individuo de la población y a éste probarlo con cada uno de los patrones de entrenamiento utilizando la función de predicción de la red neuronal. teniendo así $\mathcal{O}(PTNM)$.
- La Selección de la población a reproducir, consiste realizar una ruleta y seleccionar la mitad de la población, lo cual tiene una complejidad de $\mathcal{O}(P)$.
- El cruce de los individuos consiste en generar nuevos individuos, lo cual implica recorrer cada cromosoma de toda la población y generar nuevos, dejando una complejidad temporal de $\mathcal{O}(PG)$.

- El reemplazo de los individuos en la población consiste en cambiar algunos individuos, que en el peor caso sería reemplazarlos todos, por lo tanto la complejidad temporal será $\mathcal{O}(P)$.

A partir de estos pasos secuenciales se tiene que:

$$\begin{aligned}
&= \mathcal{O}(PTNM) + \mathcal{O}(P) + \mathcal{O}(PG) + \mathcal{O}(P) \\
&= \mathcal{O}(PTNM + P + PG + P) \\
&= \mathcal{O}(PTNM + 2P + PG) \\
&= \mathcal{O}(PTNM)
\end{aligned}$$

Igualmente que en el entrenamiento de backpropagation, en algoritmos genéticos se usa el “punto de aburrimiento”, lo cual implica la ejecución del algoritmo hasta que éste punto se cumpla, dejando una complejidad final así: $I = \text{Punto de aburrimiento} / \text{cantidad de iteraciones}$.

$$\mathcal{O}(IPTNM) \tag{11}$$

Complejidad Espacial: La complejidad espacial del algoritmo consiste el almacenar los individuos de toda la población, y cada individuos está construido por su cromosoma, por lo tanto se tendría que:

$$\mathcal{O}(PG)$$

Sabiendo que el tamaño de la población (G) es igual a $MN + M + 2$ por la ecuación 8, se concluye que.

$$\begin{aligned}
&\mathcal{O}(P(MN + M + 2)) \\
&\mathcal{O}(PMN)
\end{aligned}$$

5.5. SVM

La Técnica de computación, Máquina de soporte vectorial(SVM), es una técnica encargada de encontrar hiperplanos que separen los datos y así categorizarlos. Para lograr ésto, SVM utiliza lo que se llama vectores de soporte, los cuales se encargan de darle posición al hiperplano. Como se aprecia en la imagen 3, pueden haber muchos hiperplanos que den solución al problema, pero los vectores de soporte son los encargados de encontrar el hiperplanlo óptimo, el cual esté a una distancia equidistante de las dos categorías.

En el ejemplo se está usando solo dos dimensiones, pero para el proyecto actual se necesita un total de 19 dimensiones, ya que es la cantidad de características de la base de datos. Y SVM Funciona también para varias dimensiones, encontrando más cantidad de vectores de soporte para adaptarse al número de dimensiones necesarias.

En algunos problemas de categorización los datos no se comportan de forma lineal por lo que toca usar funciones no lineales para lo que SVM puede modificar el kernel para

encontrar hiperplanos que no lineales y poder clasificar mejor los datos. Para esto SVM utiliza principalmente 4 kernels diferentes:

$$Lineal : \langle x, x' \rangle$$

$$Polinomial : (\gamma \langle x, x' \rangle + r)^d$$

$$Exponencial : (-\gamma |x - x'|^2)$$

$$Sigmoide : \tanh(\langle x, x' \rangle + r)$$

Para decidir qué kernel que se debe usar en la implementación de SVM, se va a analizar el comportamiento de los datos a partir de una matriz de correlación 11 y visualizar el diagrama de dispersión de algunas variables que pueden ser relevantes.




Figura 11: Matriz de correlación

En la matriz de correlación los colores rojos muestran una correlación positiva y los colores azules correlación negativa. Donde se puede evidenciar que los datos de X2 a X7 que corresponden a los microaneurismas están muy relacionados entre ellos, como también

los datos de X8 a X16 que corresponde a los exudados están muy relacionados entre ellos. Se harán tres comparaciones de datos, una con alta correlación positiva, una con correlación nula y por último una correlación negativa. En las imágenes de comparación de datos se podrá encontrar dos tipos de gráficas, en la diagonal principal un diagrama de distribución de los datos, y en las otras un diagrama de dispersión la cual permite ver la correlación entre ellos.




Figura 12: Diagrama de comparación de los datos X7 y X16, Correlación Nula

En la gráfica 12, se puede ver que los datos no tiene algún comportamiento en concreto, por esto la matriz de correlación muestra que es nula, además en la diagonal principal muestra que X7 se distribuye de forma lineal y X16 de forma normal. Lo cual no deja indicios de qué función de kernel se puede usar para la clasificación.




Figura 13: Diagrama de comparación de los datos X7 y X8, Correlación Negativa

Continuando con el análisis de la comparación, en la gráfica 13 se puede ver que las dos variables tiene un comportamiento exponencial descendiente. por lo que deja un indicio de que un kernel exponencial puede servir para la clasificación.




Figura 14: Diagrama de comparación de los datos X6 y X7, Correlación Positiva

Terminando con las imágenes de comparación, se tiene la gráfica 13, la cual muestra evidentemente un alto comportamiento lineal entre las dos variables, validando que la correlación entre estas dos variables sea positivo, y dejando un indicio de que un kernel lineal puede ser la solución al problema de qué kernel usar.

Al haber terminado este análisis, se concluye un kernel Lineal y un Kernel Exponencial tienen el potencial de ser buenos clasificadores para el problema actual.

Por otra parte, los datos de entrenamiento en este algoritmo, se pueden usar sin necesidad de utilizar otro procesamiento más a como se tienen las características en la base de datos original, por lo que se utilizarán 19 características a diferencias del caso de las redes neuronales el cual usa 55, los cuales son obtenidos después del procesamiento especial para éstas. Aunque perfectamente SVM se puede usar con las 55 características la decisión de usar solo las 19, se toma ya que beneficia la complejidad del algoritmos y el tiempo de entrenamiento para las pruebas será más corto.

Ya habiendo definido el kernel y con los datos de entrenamiento y pruebas listos, se procede a la implementación de SVM, para esto se usó una librería de apoyo llamada scikit-learn⁷, la cual permite entre muchas cosas, entrenar y generar modelos de SVM con diferentes kernels. El uso de ésta se debe a que tiene una implementación muy limpia y óptima del algoritmo, además permite una amplia gama de configuraciones al momento del entrenamiento para tener un buen entendimiento del problema y el funcionamiento del algoritmo.

5.5.1. Complejidad SVM

Complejidad Temporal: La complejidad temporal del algoritmo puede variar un poco, dependiendo del kernel que se esté usando. Para entender la complejidad primero se debe definir dos variables:

- C = cantidad de Características de la Base de Datos.
- T = cantidad de patrones de entrenamiento.

La complejidad temporal dependiendo del kernel puede variar entre $\mathcal{O}(T^2)$ y $\mathcal{O}(T^3)$. Por otra parte la complejidad temporal del entrenamiento es: $\mathcal{O}(N)$.

Para terminar, ya que por cada característica se debe recorrer los patrones de entrenamiento se debe multiplicar las complejidades parciales y dejando el peor caso, se obtiene la siguiente complejidad:

$$\mathcal{O}(T^3 N). \tag{12}$$

⁷Se puede encontrar en el siguiente link: <http://scikit-learn.org>

6. Pruebas:

Al ejecutar las pruebas, los modelos y sus características son guardadas en archivos de texto. todos estos archivos de las pruebas se pueden encontrar en el repositorio del proyecto. URL: <https://github.com/hector2603/trabajoDeGrado/>.

Para estandarizar las pruebas, cada una fue corrida durante 5 horas en una máquina virtual con la siguientes características:

- 1 CPU, 2.5 GHz, Intel Xeon Family.
- 1 GB memory.
- Sistema Operativo Linux Amazon

6.1. Backpropagation:

Para ejecutar las pruebas de backpropagation primero se debe determinar el número de neuronas de la capa oculta, lo cual puede ser un trabajo de prueba y error. Para tener un inicio o un rango más acotado de pruebas, primero se debe usar un número de neuronas igual al número de datos de la base de datos, el cual sería 19 neuronas. A partir de este número se puede variar ± 10 para obtener un rango de $[9, 29]$, dejando así 20 posibles soluciones, que a su vez este conjunto de pruebas se ejecutará 3 veces, dejando en total 60 entrenamientos de prueba a realizar para obtener su precisión y poder decidir cuál es el número de neuronas indicado.

En todas las Pruebas de backpropagation se usó el 80 % de los datos para el entrenamiento y el 20 % de los datos para las pruebas de precisión.

A partir de la tabla 6 se puede evidenciar que todas las precisiones superan el 70 %, y la mayor precisión se encontró con 19 neuronas en la capa oculta, a medida que se modificaba la cantidad de neuronas y se alejaba de 19 neuronas, la precisión fue disminuyendo sustancialmente.

Para visualizar el comportamiento del error cuadrático medio (ECM), se van a usar tres pruebas en concreto:

- Prueba con Menor número de neuronas.
- Prueba con Mayor número de neuronas.
- Prueba con la mejor precisión.

Neuronas	Prueba 1	Prueba 2	Prueba 3	Promedio Precisión
9	79,2 %	72,3 %	80,2 %	77,23 %
10	76,37 %	69,20 %	82,96 %	76,18 %
11	79,99 %	72,18 %	86,59 %	79,59 %
12	82,71 %	72,13 %	87,05 %	80,63 %
13	84,42 %	73,98 %	85,31 %	81,24 %
14	83,23 %	78,18 %	85,03 %	82,15 %
15	84,57 %	77,06 %	85,22 %	82,29 %
16	85,17 %	76,62 %	83,71 %	81,83 %
17	82,58 %	73,13 %	80,90 %	78,87 %
18	84,32 %	78,25 %	84,31 %	82,30 %
19	82,18 %	83,98 %	91,6 %	85,92 %
20	75,28 %	72,37 %	79,21 %	75,62 %
21	74,32 %	75,90 %	79,46 %	76,56 %
22	72,46 %	71,93 %	75,56 %	73,32 %
23	73,67 %	73,40 %	73,25 %	73,44 %
24	70,44 %	70,50 %	73,05 %	71,33 %
25	74,16 %	67,15 %	69,81 %	70,37 %
26	73,62 %	70,52 %	66,79 %	70,31 %
27	69,65 %	75,78 %	68,31 %	71,24 %
28	71,74 %	79,64 %	70,64 %	74,01 %
29	72,58 %	77,22 %	67,73 %	72,51 %

Tabla 6: Precisión Pruebas Backpropagation




Figura 15: Comportamiento Backpropagation.

A partir de la gráfica 15, se puede determinar cosas importantes. En el eje X de la gráfica se cuentan las iteraciones del algoritmo backpropagation; y como se explicó en la ecuación 7 el número de neuronas afecta la complejidad temporal del algoritmo y esto se puede evidenciar en que la prueba con 29 neuronas llegó a una iteración más baja a comparación de las otras dos. Por otra parte, la prueba con 9 neuronas llegó a la iteración más alta, pero se puede ver que su error en gran parte de las iteraciones ya no tenía una mejora evidente, dejando así a la prueba con 19 neuronas en un punto intermedio de iteraciones, donde no se afecta demasiado la complejidad temporal, pero tampoco se queda en iteraciones de ocio. Además al observar la convergencia del ECM en la prueba con 19 neuronas es mucho mejor que las otras dos, ya que obtiene valores muchos más bajos del ECM.

Dado lo expuesto anteriormente se puede decir que la red neuronal artificial con 19 neuronas en la capa oculta es la que obtuvo mejores resultados en las pruebas realizadas, y ésta será la prueba que se usará para las comparaciones realizadas después.

6.2. Algoritmos Genéticos:

Para las pruebas de los algoritmos genéticos se deben tener en cuenta diferentes variables que pueden generar una cantidad muy grande de combinaciones, por lo tanto éstas se deben limitar para generar un conjunto de combinaciones más discreto.

Variables	Dato 1	Dato 2
Población	50	100
Reemplazo	Inserción	Élite
Mutación	8 %	20 %
Escalado	Sí	No

Tabla 7: Variables del algoritmo genético

Reemplazo Élite: Corresponde en reemplazar un gran porcentaje de la población. 88 % en el caso de una población de 50 y 94 % en caso de una población de 100.

Reemplazo Inserción: Corresponde en reemplazar la mitad de la población, en cualquier caso del tamaño de la población, se reemplazará la mitad.

Dada estas 4 variables, darían 16 combinaciones del algoritmo genético. que se representan en la siguiente tabla 8.

Para comenzar el análisis de las pruebas se va ir acotando el grupo de pruebas, hasta llegar a un grupo más pequeño sobre el cual se pueda sacar una conclusión del algoritmo. Para tener un punto de comparación se va a usar la gráfica de comportamiento 16 que corresponde a la prueba número 2 en tabla 8, ya que según la teoría de algoritmos evolutivos estos parámetros son los más estándar, además todas las pruebas se ejecutan 5 horas para tener un tiempo estándar y se pueda hacer la comparación.

Número de prueba	Población	Mutación	Reemplazo	Escalado
1	50	8 %	Inserción	Sí
2	50	8 %	Inserción	No
3	50	8 %	Élite	Sí
4	50	8 %	Élite	No
5	50	20 %	Inserción	Sí
6	50	20 %	Inserción	No
7	50	20 %	Élite	Sí
8	50	20 %	Élite	No
9	100	8 %	Inserción	Sí
10	100	8 %	Inserción	No
11	100	8 %	Élite	Sí
12	100	8 %	Élite	No
13	100	20 %	Inserción	Sí
14	100	20 %	Inserción	No
15	100	20 %	Élite	Sí
16	100	20 %	Élite	No

Tabla 8: Combinaciones de las pruebas de algoritmos evolutivos

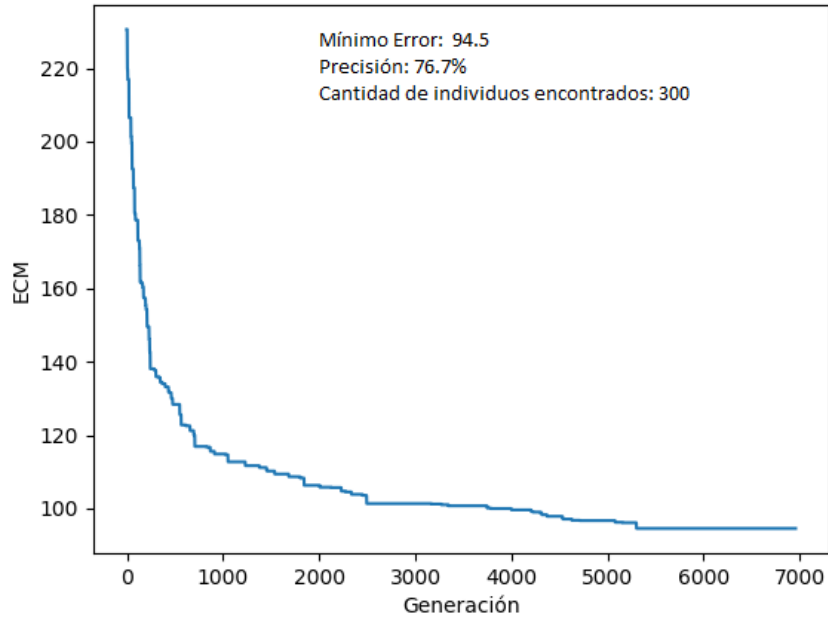


Figura 16: Comportamiento algoritmo evolutivo, Prueba número 2.

Escalado: Para las pruebas se comenzó con un escalado de 1,1 y 0,9, lo que significa se está variando en un 10 % de su valor inicial, lo que hacía que se obtuviera un comportamiento de la convergencia de la siguiente forma.

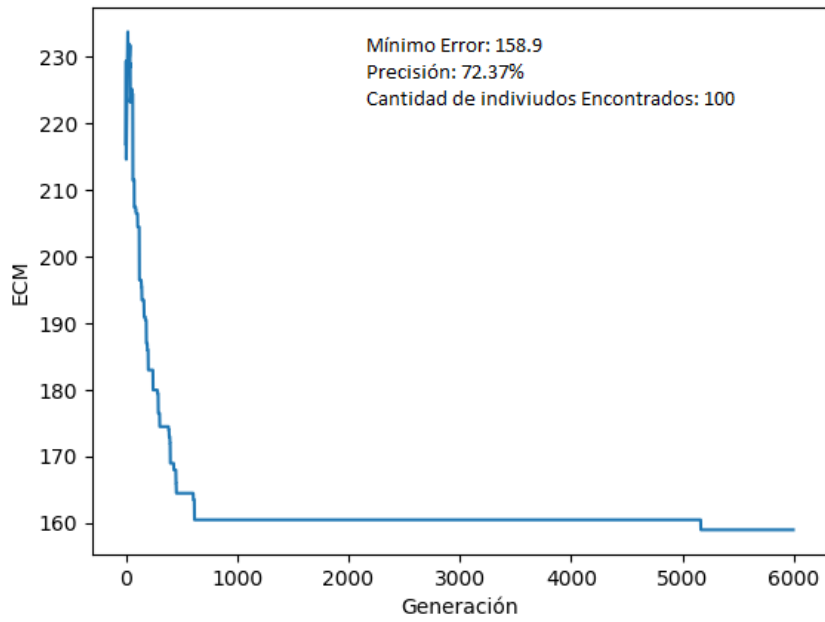


Figura 17: Comportamiento algoritmo evolutivo, con un escalado de 1,1.

En la gráfica 17, se puede ver el comportamiento del error a través de las generaciones, la prueba corresponde a la número 1 en la tabla 8, con un escalado de 1,1. en la gráfica se nota que el error aumenta y generaciones después se estanca, consiguiendo en toda la ejecución 100 individuos mejores a comparación de la población inicial, en lo que se puede decir que en promedio cada 60 generaciones encontró un individuo que mejora al anterior, teniendo como resultado que este escalado no da una buena convergencia.

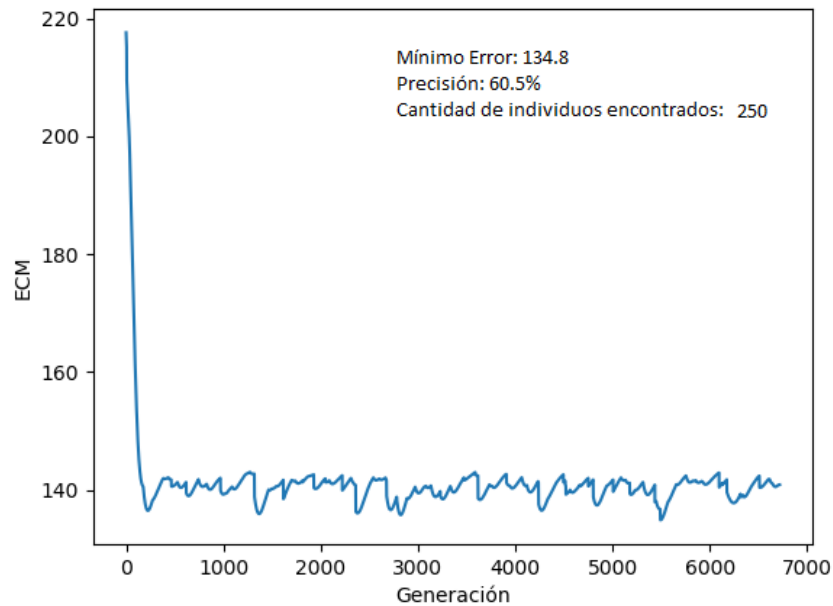


Figura 18: Comportamiento algoritmo evolutivo, con un escalado de 0,9.

En la gráfica 18, se puede ver el comportamiento del error a través de las generaciones de la prueba número 7 en la tabla 8, con un escalado de 0,9. a diferencia del escalado 1,1. está tiene una convergencia inicial muy rápida donde todavía el umbral de mejora es muy grande, pero después cae en una oscilación de la no sale, ya que el comportamiento comienza a variar tanto, el número de individuos que mejoran al inicial, aumento a 250, lo que puede decir que en promedio cada 30 generaciones encontró un individuo que mejora al anterior.

Continuando con las pruebas del escalado y en busca de buenos resultados, se considera disminuir considerablemente el valor de escalado, por cantidades de 1,0000001 y 0,999999. significando que está cambiando un 0.0001 % con respecto a su valor inicial y obteniendo los siguientes comportamientos:

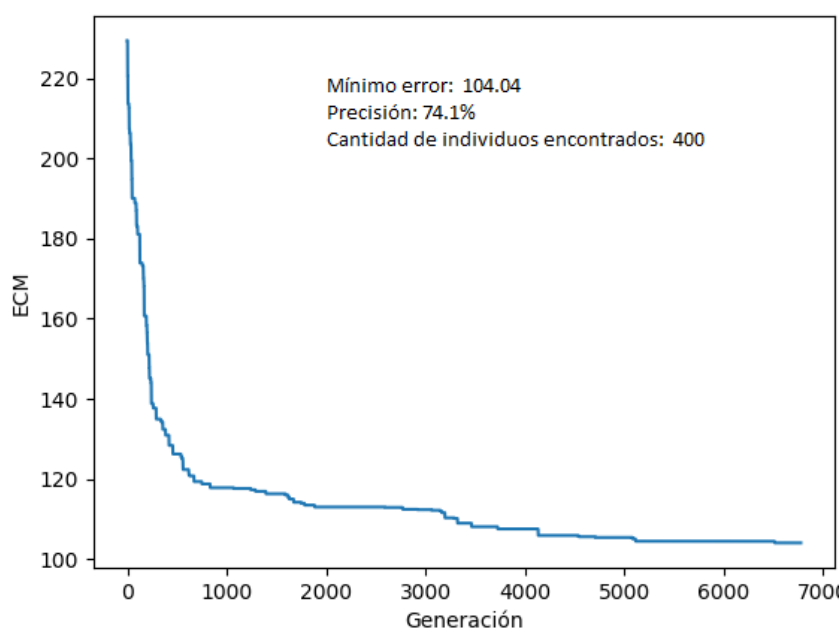


Figura 19: Comportamiento algoritmo evolutivo, con un escalado de 1,0000001.

En la gráfica 19, se puede ver el comportamiento del error a través de las generaciones de la prueba número 3 en la tabla 8, con un escalado de 1,0000001, ésta tiene una convergencia sin picos y acercándose a una asíntota; qué es un resultado esperado, y a comparación de las gráficas 18 y 17, la precisión aumentó por lo que se puede decir que éste escalado mejora el comportamiento a comparación de los otros dos.

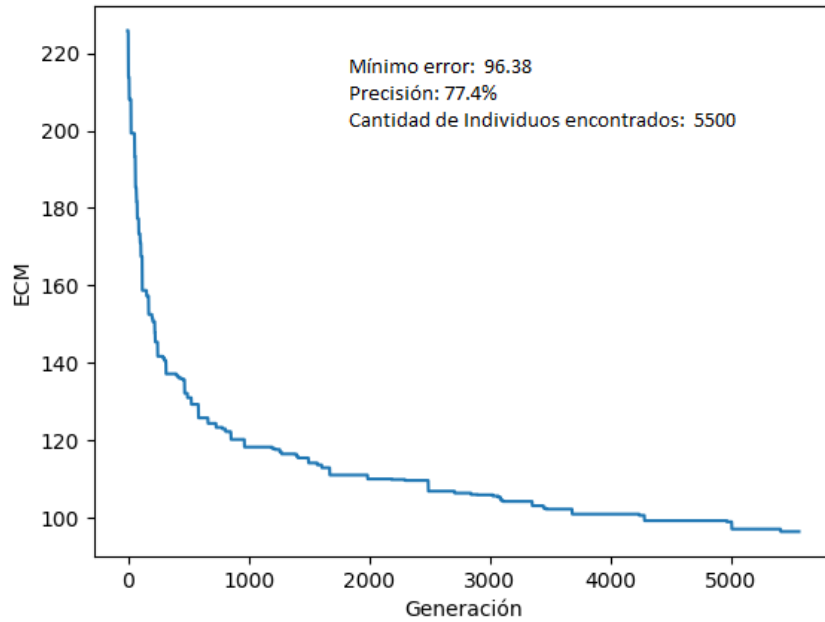


Figura 20: Comportamiento algoritmo evolutivo, con un escalado de 0,999999.

En la gráfica 20, se puede ver el comportamiento del error a través de las generaciones de la prueba número 1 en la tabla 8, con un escalado de 0,999999 tiene una convergencia esperada, ésta obtuvo la mejor precisión a comparación de las demás pruebas con escalado y un resultado a destacar. la cantidad de individuos que mejoran al anterior es de 5500 y en la ejecución de la prueba se llegó a 5800 generaciones, por que en promedio hubo un individuo por generación, lo que quiere decir que cada generación se fue mejorando el resultado.

Para concluir, con el escalado de 0.999999 se puede decir que llegó al resultado de precisión en saltos más pequeños ya que se encontraron 5500 individuos, y así obtuvo un resultado parecido al de gráfica de comparación 16 la cual tuvo solo 300 individuos. por lo que se puede decir que un escalado de un porcentaje muy alto no es viable y un escalado muy pequeño es bueno, pero se tiene el mismo resultado a como si no se tuviera, dejando así el escalado por fuera del conjunto de prueba y acotando el conjunto a 8 pruebas.

Población: Continuando con el análisis de las pruebas, la población inicial es un parámetros muy importante en los algoritmos genéticos, ya que una población muy baja no permite que haya variabilidad ni competencia, y una población muy alta implica que el tiempo de ejecución se crecerá, ya que la complejidad temporal depende de la población, como se pudo evidenciar en la ecuación 11. En las pruebas se tiene que la población es de 50 y 100 individuos.

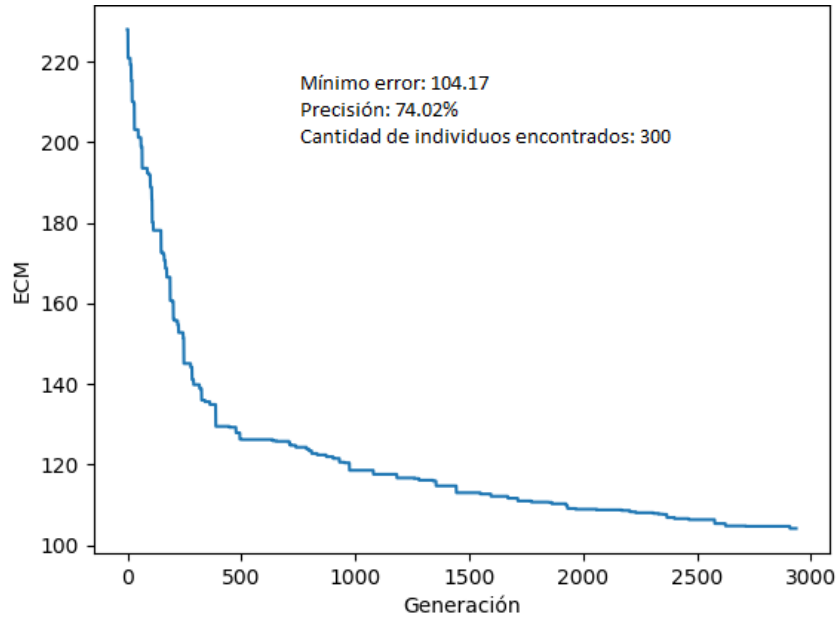


Figura 21: Comportamiento algoritmo evolutivo, con una población de 100

En la gráfica de comportamiento 16 se está usando una población de 50 individuos, ésta llega a la generación 7000 y alcanza un mínimo error de 94.5. Por otra parte tenemos la gráfica de comportamiento 21 la cual está usando una población de 100 individuos y ésta llega a la generación 2900, casi a la mitad de generaciones a comparación de la de 50 individuos; por otra parte los resultados de precisión son muy cercanos pero aún así la prueba con 100 individuos le faltó más tiempo de convergencia para alcanzar el mismo resultado de la prueba de 50 individuos.

Por lo tanto la población de 100 individuos se puede dejar fuera del conjunto de pruebas, ya que ésta aumenta la complejidad temporal del algoritmo, y demora un poco la convergencia de la prueba, quedando así un conjunto de 4 pruebas, a comparación de las 16 iniciales.

Pruebas Finales: El conjunto de pruebas finales de los algoritmos genéticos es el siguiente:

Número de prueba	Población	Mutación	Reemplazo	Escalado
2	50	8 %	Inserción	No
4	50	8 %	Élite	No
6	50	20 %	Inserción	No
8	50	20 %	Élite	No

Tabla 9: Pruebas Finales

El comportamiento de de estas 4 pruebas se puede ver en la siguiente gráfica:




Figura 22: Comportamiento de las 4 Pruebas.

Al comparar el comportamiento del error cuadrático medio de estas 4 pruebas, se puede evidenciar que el más bajo se encuentra en la Prueba 2, dejando esta combinación de variables como las más óptimas en el problema concreto que se está trabajando en el proyecto y ésta será la prueba usada para las comparaciones más adelante.

6.3. SVM

SVM a comparación de las técnicas anteriores, no necesita muchos entrenamientos para generar una solución, ya que es determinista y todas las veces que se ejecute la prueba se va a obtener el mismo resultado, siempre y cuando se esté usando el mismo conjunto de datos de entrenamiento.

Por lo tanto, las pruebas de SVM serán 2, una por cada kernel que se implementó y al ejecutarse se obtuvo los siguientes resultados.

Kernel	Precisión	Sensibilidad	Especificidad
Lineal	72.7 %	61.5 %	87.7 %
Exponencial	53.3 %	51.6 %	20.9 %

Tabla 10: Resultados Pruebas SVM

Al ver los resultados obtenidos, el kernel lineal tuvo mejores resultados comparados con el kernel exponencial. además esto verifica que muchas de las características en la base de datos se comportan de forma lineal y no de forma exponencial.

7. Prototipo

La Implementación de los algoritmos, como la implementación del prototipo se hizo bajo la metodología TDD, esta consiste en generar las pruebas antes de comenzar la codificación, lo cual ayuda a entender qué es lo que se va a implementar y cuál es el resultado esperado, y si después de la implementación el resultado es satisfactorio, se continúa con la siguiente prueba y comenzar el ciclo de nuevo.

La implementación del proyecto actual se dividió principalmente en 4 partes:

1. Backpropagation
2. Algoritmos Genéticos
3. SVM
4. Interfaz Gráfica

Los tres primeros pasos al ser los algoritmos de decisión, se puede dividir en un mismo conjunto de pruebas, sabiendo que para cada algoritmo se espera resultados y especificaciones diferentes.

- Entrenamiento.
- Pruebas.
- Guardar Modelo.
- Generar Gráficas.

El último paso que corresponde a la interfaz gráfica, se dividió en pruebas más pequeñas, las cuales correspondían a funcionalidades de la interfaz gráfica y que hasta no terminarla, no se continuaba con la otra, permitiendo al final tener certeza de que todo lo que se implementó funciona.

En la gráfica 23, se muestra la ventana principal de la interfaz, aquí se puede encontrar diferentes funciones, probar cada uno de los modelos que obtuvieron el resultados en las pruebas, además comprobar los resultados de cada uno en la matriz de confusión y al final hacer una categorización concreta que se quiera.

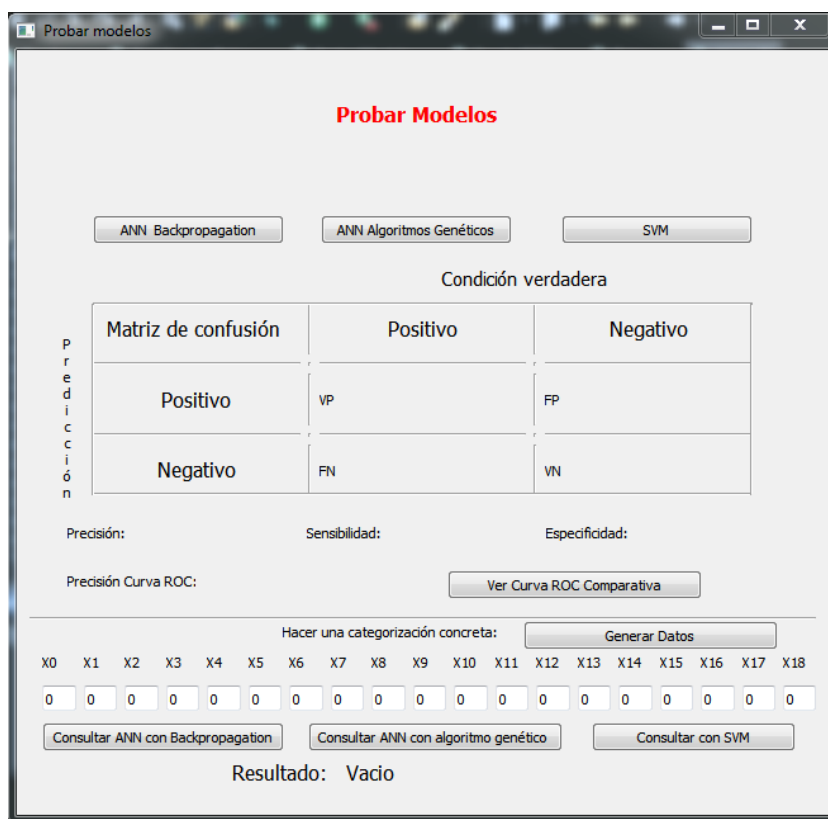


Figura 23: Captura de la pantalla Principal de la interfaz

Para concluir se puede decir que TDD permitió un buen desarrollo del proyecto, alcanzando los objetivos en el tiempo esperado y con pocos imprevisto sobre la marcha, ya que al tener las pruebas claras desde un inicio; ayudó a entender el problema y lo que se debía hacer.

8. Comparación:

En el capítulo anterior se dejó 3 modelos diferentes, que deben ser comparados para poder llegar a una conclusión de cuál de los 3 es la mejor solución obtenida en el proyecto actual. La comparación se hará a partir de la curva ROC, esta gráfica nos permite ver el ratio de verdaderos positivos contra el ratio de falsos positivos.

En la descripción del problema se planteó que una buena precisión en el diagnóstico de los médicos es indispensable, dicho de otra forma es que el ratio de verdaderos positivos debe ser alto, lo que significa que el médico está diagnosticando con total precisión los casos positivos cuando la enfermedad sí se encuentra, siendo éstos los casos que son importantes y delicados para el paciente.

Por lo que la curva ROC permite ver de manera más clara, cuál de los tres modelos responde mejor a aumentar el ratio de verdaderos positivos y a su vez disminuye el ratio

de falsos positivos, el cual corresponde a las malas predicciones. A partir de los verdaderos positivos y los falsos positivos se tiene una forma diferente de calcular la precisión del modelo, la cual corresponde al área bajo la curva.

En la gráfica 24, se puede encontrar las curvas que corresponden a cada uno de los 3 modelos, además se indica el área bajo la curva de cada una y deja al modelo de backpropagation como la mejor respecto a las otras dos con una precisión del 94 %.

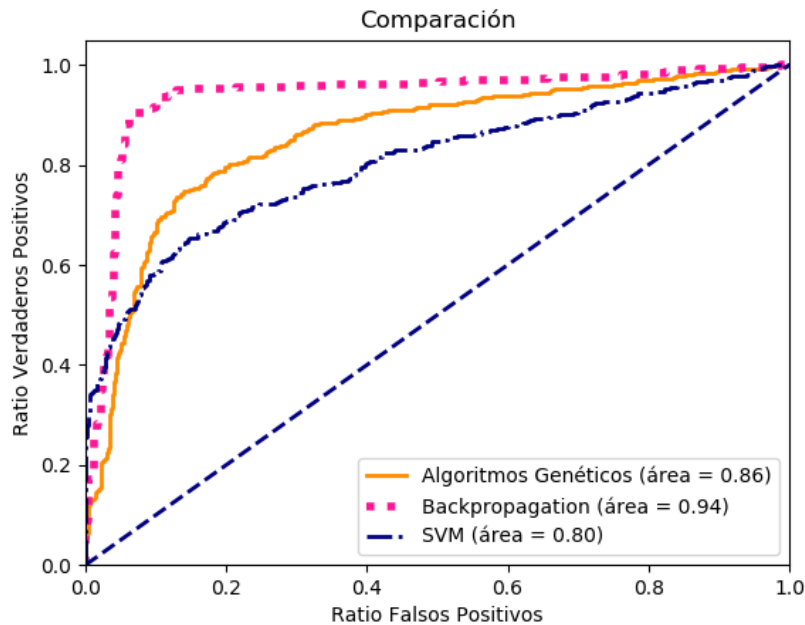


Figura 24: Curva ROC Comparando las diferentes técnicas

Característica	Backpropagation	Algoritmos genéticos	SVM
Dependencia	Backpropagation depende mucho del primer modelo generado aleatoriamente, ya que utiliza derivadas para ir llegando a óptimos, por lo que si el primer modelo está ubicado cerca de un óptimo local, puede llegar a quedar en éste y no salir.	Los modelos encontrados con algoritmos genéticos dependen parcialmente de las primeras generaciones, ya que por medio de la mutación y reproducción la variabilidad va aumentando, dándole la facilidad de que si se está en un óptimo local, se pueda salir y seguir buscando en el dominio de las posibles soluciones.	SVM a diferencia de las otras dos técnicas no dependen de un estado inicial de ejecución, sino que depende de los datos de entrenamiento, ya que a partir de estos es que se encuentran los vectores de soporte. Entonces, como en todas las ejecuciones del programa, los datos de entrenamiento siempre serán los mismos, se espera que la precisión del algoritmos sea el mismo.
Tiempo	Backpropagation puede tener una convergencia más rápida a comparación de los algoritmos genéticos, el problema es que si en algún momento cae en un óptimo local, por más tiempo que dure la ejecución nunca llegará a una solución.	Los algoritmos genéticos tienen una convergencia muy lenta y como se puede ver en la ecuación 11, que corresponde a la complejidad temporal, ésta depende de diferentes variables que pueden aumentar ampliamente la complejidad, además como en algunos casos el punto final o punto de aburrimiento no se tiene claro quiere decir que el algoritmos se puede dejar ejecutando por mucho tiempo y puede que no encuentre alguna solución aceptable	SVM a comparación de los otros dos algoritmos tiene un tiempo de ejecución más bajo, ya que éste depende de menos variables para el entrenamiento, como se puede ver en la ecuación 12 de complejidad temporal .

Característica	Backpropagation	Algoritmos genéticos	SVM
Resultados	En la diferentes pruebas de backpropagation, el primer modelo se generó con números aleatorios de 0 a 1 y en todos los modelos obtenidos al final se pudo caracterizar que los pesos de la primer capa varían entre $[-1,1]$ y los de la capa de salida entre $[-7,7]$.	Como ya se explicó en la implementación del algoritmo genético, la primer generación cumple una regla para generarla, que se determinó a partir de backpropagation, pero en los resultados obtenidos en todas las pruebas se pudo ver que los modelos ya no cumplían esta regla, lo cual verifica que los algoritmos genéticos tienen una gran variabilidad.	Dado a qué SVM es determinista, las pruebas en esta técnica son más limitadas, y por más que se ejecute el algoritmos diferentes veces con el mismo conjunto de datos de entrenamiento, siempre se va a obtener el mismo resultado.
Precisión	Backpropagation alcanzó la mejor precisión con un 94 %.	La mejor precisión alcanzada en el entrenamiento por algoritmos genéticos fue de 86 %.	SVM con un kernel lineal, alcanzó una precisión del 80 %

Tabla 11: Comparación.

9. Conclusiones:

1. El conocimiento adquirido sobre retinopatía diabética, advierte la importancia que se debe tener sobre ella, ya que un caso de descuido o un mal cuidado, puede generar grandes problemas en la persona y en algunos casos ser irreversible como lo puede ser la perdida total o parcial de la visión.
2. El diseño y la implementación de los algoritmos, corresponde a una serie de pasos que comienzan por entender el problema de la clasificación de la retinopatía diabética, después generar posibles soluciones a partir de los estudios realizados y por último llevarlas a una implementación de software; toda esta serie de pasos además de responder a un objetivo del actual proyecto, también da respuesta a un objetivo importante de la ingeniería de sistemas, el cual consiste en darle respuesta a un problema de la vida real con software y que en próximos proyectos el conocimiento adquirido pueda ser extrapolado y adaptado para poder conseguir iguales o mejores resultados que los actuales.
3. La implementación de los algoritmos se realizó en el lenguaje de programación Python 3.7, y se complementó con el uso de diferentes librerías las cuales vienen optimizadas para el lenguaje de programación y cuentan con una amplia documentación, lo

cual favorece a ahorrar tiempo en implementaciones y entendimiento de las funciones usadas. A partir de lo anterior se puede decir que se obtuvo buenos resultados en el ámbito de la codificación y concluir que Python es un buen lenguaje de programación para el tipo de problemas como el del proyecto actual.

4. El entrenamiento de SVM es 60 veces más rápido que el entrenamiento de redes neuronales utilizando BackPropagation y Algoritmos Evolutivos, ya que mientras uno demora 5 minutos el otro demora 5 horas. Esto se evidenció durante las pruebas realizadas, y se debe a que la estrategia BackPropagation requiere una gran cantidad de cálculos, mientras que la estrategia evolutiva tiene una velocidad de convergencia lenta.
5. Al realizar las pruebas, se observaron algunos patrones importantes; los modelos resultantes de BackPropagation siempre convergen a que los pesos de la capa oculta están en un rango de números de $[-1,1]$ y los pesos de la capa de salida están entre $[-7,7]$, que comparados con los modelos resultantes de algoritmos evolutivos, en estos se pueden encontrar pesos muy diferentes, desde muy pequeños a muy grandes, dándole así una habilidad de no quedar atascado en óptimos locales y no siempre converger a un mismo conjunto de soluciones.
6. BackPropagation alcanzó la mejor precisión con un 94 %, no obstante, esta técnica depende mucho del modelo inicial, lo que implica una posible desventaja, ya que al estar ligado al modelo inicial no explora sobre todo el dominio de solución y termina quedando generalmente sobre óptimos locales, pero aún así se puede decir que BackPropagation da respuestas con buena precisión y modelos útiles para sistemas de recomendación.
7. Los algoritmos genéticos obtuvieron una menor precisión con un 86 %, pero dada la cualidad de tener una gran variabilidad se puede explorar más los espacios de búsqueda y no caer en óptimos locales, además al tener un alto componente estocástico se puede decir que los algoritmos genéticos están más cerca de llegar a una precisión del 100 %, ya que no se puede determinar que se va a encontrar a través de las generaciones.
8. SVM obtuvo la precisión más baja con un 80 %, pero éste tiene un gran ventaja a comparación de las otras dos, la cual es que SVM es determinista, lo que implica que no se necesita de muchas pruebas para generar un modelo y éste poder ser usado en sistemas de recomendación.
9. Al momento de decidir qué técnica usar en un sistema de recomendación, se pueden generar 3 ambientes: El primero sería en el que se necesita la mejor precisión en un tiempo moderado, aquí la decisión sería implementar Backpropagation ya que corresponde a la mejor precisión. En segundo lugar se encuentra un ambiente donde se necesita una implementación rápida, ya que no se tiene tiempo para muchas pruebas y se puede sacrificar un poco la precisión del sistema, aquí la decisión sería SVM. en último lugar sería un ambiente de investigación el cual cuente con mucho

tiempo para pruebas, aquí la decisión podría ser Algoritmos genéticos, sobre el cual se puede generar gran cantidad de pruebas, con diferentes opciones de configuración del modelo.

10. Como dice el artículo [7], los diagnósticos médicos se pueden ver afectados por variables como el exceso de confianza, presentando que la precisión de diagnóstico es del 55.3 %, que comparada con la precisión obtenida en el actual proyecto es menor; además como dice el artículo [15], la precisión de los profesionales puede verse mejorada al utilizar un sistema de recomendación. A partir de lo expuesto se puede concluir que la dada precisión obtenida en el actual proyecto, el algoritmo de redes neuronales entrenadas por backpropagation puede ser usado por sistemas de recomendación, para que éste sirva de ayuda al profesional a mejorar su precisión o a comparar su propio dictamen con el del sistema y tener otro punto de vista.

9.1. Trabajos Futuros:

1. El proyecto actual trabaja sobre una base de datos obtenida del procesamiento de imágenes a partir de diferentes proyectos de apoyo, por lo que un trabajo futuro será implementar un procesamiento de imágenes propio, lo cual servirá para generar más datos de entrenamiento y posteriormente automatizar más el proceso del médico ya que la entrada del sistema será directamente las imágenes.
2. Como se especificó en el alcance, en el proyecto actual solo es un prototipo de sistema que recibe los valores de las características para generar una categorización positiva o negativa, por lo que un trabajo futuro será generar un sistema completo para el uso de un usuario final.
3. Por la parte de la investigación, un trabajo futuro será implementar diferentes algoritmos de decisión que sean probados bajo unas condiciones parecidas a las del proyecto actual y así continuar comparando los algoritmos y determinar cuál es el mejor de todos, en el caso concreto de la retinopatía diabética.

10. Referencias

- [1] E. Coiera, *Guide to medical informatics, the internet and telemedicine*. Chapman & Hall, Ltd., 1997.
- [2] S. S. Sikchi, S. Sikchi, and M. Ali, "Artificial intelligence in medical diagnosis," *International Journal of Applied Engineering Research*, vol. 7, no. 11, p. 2012, 2012.
- [3] M. Colombia, "Colombia enfrenta epidemia de enfermedades cardiovasculares y diabetes." <https://www.minsalud.gov.co/Paginas/Colombia-enfrenta-epidemia-de-enfermedades-cardiovasculares-y-diabetes.aspx>, 2017. última visita 9 mayo del 2017.

- [4] A. S. Fauci *et al.*, *Harrison's principles of internal medicine*, vol. 2. Mcgraw-hill New York, 1998.
- [5] O. mundial de la salud, "Diabetes, datos y cifras mundiales." <http://www.who.int/mediacentre/factsheets/fs312/es/>, 2017. última visita 9 mayo del 2017.
- [6] Tecnoquimicas, "Guia retinopatía diabética latinoamérica," *tecnoquimicasfarma*, 2012.
- [7] A. N. Meyer, V. L. Payne, D. W. Meeks, R. Rao, and H. Singh, "Physicians' diagnostic accuracy, confidence, and resource requests: A vignette study," *JAMA Internal Medicine*, vol. 173, no. 21, pp. 1952–1961, 2013.
- [8] E. H. Shortliffe, R. Davis, S. G. Axline, B. G. Buchanan, C. C. Green, and S. N. Cohen, "Computer-based consultations in clinical therapeutics: explanation and rule acquisition capabilities of the mycin system," *Computers and biomedical research*, vol. 8, no. 4, pp. 303–320, 1975.
- [9] G. S. Novak, "tmycin expert system tool." <http://www.cs.utexas.edu/users/novak/tmycin.html>, 2017. última visita 9 mayo del 2017.
- [10] B. Auvert, P. Aegerter, V. Gilbos, E. Benillouche, P. Boutin, G. Desve, M. Landre, and D. Bos, "Tropicaid: a portable expert system for medical decision-aid in developing countries," *Medinfo*, vol. 86, pp. 222–224, 1986.
- [11] F. C. Hoppensteadt and C. Peskin, *Modeling and simulation in medicine and the life sciences*, vol. 10. Springer Science & Business Media, 2012.
- [12] M. Stahl, T. Aach, and S. Dippel, "Digital radiography enhancement by nonlinear multiscale processing," *Medical physics*, vol. 27, no. 1, pp. 56–65, 2000.
- [13] G. Rakocovic, T. Djukic, N. Filipovic, and V. Milutinović, *Computational medicine in data mining and modeling*. Springer, 2013.
- [14] S. Russell, P. Norvig, and A. Intelligence, "A modern approach," *Artificial Intelligence. Prentice-Hall, Egnlewood Cliffs*, vol. 25, p. 518, 1995.
- [15] L. Alonso-Carrión, F. J. Sánchez-Lora, C. Hinojosa-López, J. J. Porras-Vivas, A. Cuenca-Guerrero, and M. Abarca-Costalago, "Precisión del diagnóstico en medicina interna e influencia de un sistema informático en el razonamiento clínico," *Educacion Medica*, vol. 16, no. 3, pp. 184–187, 2015.
- [16] S. Russell and P. Norvig, "Inteligencia artificialun enfoque moderno," 2004.
- [17] A. E. Eiben, J. E. Smith, *et al.*, *Introduction to evolutionary computing*, vol. 53. Springer, 2003.
- [18] F. Izaurieta and C. Saavedra, "Redes neuronales artificiales," *Departamento de Física, Universidad de Concepción Chile*, 2000.

- [19] T. Zhang, “An introduction to support vector machines and other kernel-based learning methods,” *AI Magazine*, vol. 22, no. 2, p. 103, 2001.
- [20] “¿qué es la retinopatía diabética?.” <https://www.aao.org/salud-ocular/enfermedades/retinopatia-diabetica>, author=American Academy of Ophthalmology, 2017.
- [21] E. Decenci re, X. Zhang, G. Cazuguel, B. La y, B. Cochener, C. Trone, P. Gain, R. Ordonez, P. Massin, A. Erginay, *et al.*, “Feedback on a publicly distributed image database: the messidor database,” *Image Analysis & Stereology*, vol. 33, no. 3, pp. 231–234, 2014.
- [22] A. J. Rosales-silva and F. J. Gallegos-funes, “Detection and classification of Non-Proliferative Diabetic Retinopathy using a Back-Propagation neural network Detecci n y clasificaci n de Retinopat a Diab tica no Proliferativa usando una Red Neuronal de Retropropagaci n,” pp. 70–85, 2015.
- [23] B. Antal and A. Hajdu, “An ensemble-based system for automatic screening of diabetic retinopathy,” *Knowledge-Based Systems*, vol. 60, pp. 20–27, 2014.
- [24] T. Taveira-Gomes, “machine learning on the diabetic retinopathy debrecen data set data set.” <https://rpubs.com/tiagotaveira/debrecen>.
- [25] S. J. J. Kumar and M. Madheswaran, “An improved medical decision support system to identify the diabetic retinopathy using fundus images,” *Journal of Medical Systems*, vol. 36, no. 6, pp. 3573–3581, 2012.
- [26] S. Issac Niwas, P. Palanisamy, R. Chibbar, and W. J. Zhang, “An expert support system for breast cancer diagnosis using color wavelet features,” *Journal of Medical Systems*, vol. 36, no. 5, pp. 3091–3102, 2012.
- [27] E. Elveren and N. Yumu ak, “Tuberculosis disease diagnosis using artificial neural network trained with genetic algorithm,” *Journal of Medical Systems*, vol. 35, no. 3, pp. 329–332, 2011.
- [28] V. Cruz-Guti rrez and A. S nchez-L pez, “Un sistema experto difuso en la Web para diagn stico de diabetes,” vol. 107, pp. 145–155, 2015.
- [29] L.  lvarez Men ndez, F. J. de Cos Juez, F. S nchez Lasheras, and J. A.  lvarez Riesgo, “Artificial neural networks applied to cancer detection in a breast screening programme,” *Mathematical and Computer Modelling*, vol. 52, no. 7-8, pp. 983–991, 2010.
- [30] R. Kunhimangalam, S. Ovalath, and P. K. Joseph, “A clinical decision support system with an integrated EMR for diagnosis of peripheral neuropathy,” *Journal of Medical Systems*, vol. 38, no. 4, 2014.

- [31] M. S. Bascil and H. Oztekin, "A study on hepatitis disease diagnosis using probabilistic neural network," *Journal of Medical Systems*, vol. 36, no. 3, pp. 1603–1606, 2012.
- [32] M. S. Bascil and F. Temurtas, "A study on hepatitis disease diagnosis using multilayer neural network with Levenberg Marquardt training algorithm," *Journal of Medical Systems*, vol. 35, no. 3, pp. 433–436, 2011.
- [33] B. D. Barkana, I. Saricicek, and B. Yildirim, "Performance analysis of descriptive statistical features in retinal vessel segmentation via fuzzy logic, ANN, SVM, and classifier fusion," *Knowledge-Based Systems*, vol. 118, pp. 165–176, 2017.
- [34] M. Javidi, H.-R. Pourreza, and A. Harati, "Vessel segmentation and microaneurysm detection using discriminative dictionary learning and sparse representation," *Computer Methods and Programs in Biomedicine*, vol. 139, pp. 93–108, 2017.
- [35] W. A. Warner, R. Sanchez, A. Dawoodian, E. Li, and J. Momand, "Comparison of Standardized Clinical Classification with Fundus Photograph Grading for the assessment of Diabetic Retinopathy and Diabetic Macular Edema Severity," vol. 80, no. 4, pp. 631–637, 2013.
- [36] M. M. Nentwich, "Diabetic retinopathy - ocular complications of diabetes mellitus," *World Journal of Diabetes*, vol. 6, no. 3, p. 489, 2015.
- [37] S. Patel, R. M. Klein, A. Patel, R. B. Klein, M. Aung, and W. Hoe, "Diabetic retinopathy screening and treatment in Myanmar: a pilot study," *BMJ Open Ophthalmology*, vol. 1, no. 1, p. e000084, 2017.
- [38] N. P. Emptage, S. Kealey, F. C. Lum, and S. Garratt, "Preferred Practice Pattern: Diabetic retinopathy," *American journal of ophthalmology*, vol. Updated Ja, pp. <http://www.aaao.org/preferred-practice-pattern/diab>, 2014.
- [39] D. Aliseda Perez de Madrid and I. Berastegui, "Diabetic retinopathy," *An Sist Sanit Navar*, vol. 31 Suppl 3, no. 3, pp. 23–34, 2008.
- [40] Virgilio Lima Gomez, "Retinopatía diabética simplificada," *Rev Hosp Jua Mex*, vol. 73, no. 4, pp. 170–174, 2006.
- [41] A. Pareja-rios, S. Bonaque-gonzalez, M. Serrano-garcia, and F. Cabrera-lopez, "Teleoftalmología para el cribado de la retinopatía," vol. 92, no. 2, pp. 63–70, 2017.
- [42] O. E. Schmitz and C. E. Mogensen, "United Kingdom Prospective Diabetes Study.," *Ugeskrift for læger*, vol. 158, no. 15, pp. 2137–2139, 1996.
- [43] F. Barria von Bischhoffshausen and F. Martinez Castro, "DIRIGIDA A OFTALMOLOGOS Y PROFESIONALES DE LA SALUD Organiza: PROGRAMA VISION 2020 IAPB para America Latina 1er Taller Quito GUIA PRACTICA CLINICA DE RETINOPATIA DIABETICA PARA LATINOAMERICA," *Lsn*, vol. 2, no. 1, pp. 1–46, 2011.

- [44] M. R. A. Castillo, “Teleoftalmologia para el cribado de Retinopatía Diabética en un área de salud integrada: modelo de gestión de la demanda,” 2015.
- [45] C. Vargas-Sánchez, J. J. Maldonado-Valenzuela, F. T. Pérez-Durillo, J. González-Calvo, and A. Pérez-Milena, “Coverage and results of a screening program for diabetic retinopathy using mydriatic retinography in primary health care,” *Salud pública de México*, vol. 53, no. 3, pp. 212–219, 2011.
- [46] D. Effron, B. C. Forcier, and R. E. Wyszynski, “Chapter 3 . Funduscopic Findings Age-Related Macular Degeneration,” pp. 1–23, 2014.
- [47] S. Edición, *Atlas de la Diabetes de la FID*. 2015.
- [48] G. Mb and E. Jm, “PREVALENCIA DE RETINOPATÍA DIABÉTICA EN UNA POBLACIÓN DIABÉTICA PREVALENCE OF DIABETIC RETINOPATHY . A POPULATION BASED STUDY IN,” no. 1, pp. 7–12, 2017.